Verteilte Systeme

R. Kaiser, R. Kröger, O. Hahm

(HTTP: http://www.cs.hs-rm.de/~kaiser
E-Mail: eobert.kaiser@hs-rm.de)
Kai Beckmann
Sebastian Flothow
Alexander Schönborn

Sommersemester 2021

9. Verteilte Dateisysteme

https://tagebucheinesdeutschen.wordpress.com/2016/08/06/neues-von-der-scheinbehoerden-front-strategiewechsel-der-firma-finanzamt/comment-page-1/

Inhalt

Hochschule RheinMain

Einführung

Hochschule RheinMain

Datenhaltungssysteme

	Dateisysteme	**Datenbank-systeme**	**Objekt-management-systeme**
Inhalt	universell	Massendaten weniger struktureller Typen	Beziehungen stehen im Vordergrund
Gespeicherte Informationen	passiv	passiv	aktiv
Semantik auf-prägender Code	extern	extern	intern (Typen)
Zugriff	über Namen, einfache Navigation	komplexe assoziative Suchfunktionen	komplexe Such- und Navigations-funktionen

Modelle von Dateisystemen

Dateien als klassische Abstraktion in Betriebssystemen
Historische Entwicklung im folgenden betrachtet

1 Rechner, 1 Benutzer, 1 Prozess

- zu lösende Probleme
  - Struktur des Dateisystems
  - Benennung (Naming)
  - Programmierschnittstelle
  - Abbildung auf physikalischen Speicher
  - Integrität
- Beispiele
  - PC-DOS
  - klassisches MacOS

Modelle von Dateisystemen (2)

1 Rechner, 1 Benutzer, mehrere Prozesse

- zusätzlich zu lösende Probleme
  - Nebenläufigkeitskontrolle
- Beispiel
  - OS/2

1 Rechner, mehrere Benutzer, mehrere Prozesse

- zusätzlich zu lösende Probleme
  - Sicherheit und Rechteverwaltung
- Beispiel
  - UNIX

mehrere Rechner, mehrere Benutzer, mehrere Prozesse

- im weiteren betrachtet
- zusätzlich zu lösende Probleme
  - Verteiltheit, d.h.
    - ★ sichtbare Gesamtstruktur
    - ★ Zugriffsmodell
    - ★ Aufenthaltsort
    - ★ Replikation
    - ★ Verfügbarkeit
    - ★ ...
  - Kein Zugriff auf gemeinsamen Block-Speicher der Knoten (shared nothing)
  - Sharing gemeinsamer Platten zwischen den Knoten hier nicht weiter betrachtet (vgl. 9.5: SAN Storage Area Networks) → Cluster File Systems
- Client/Server-Modell
  - ausgezeichneter File-Server
- Peer-to-Peer-Modell
  - jeder kann Dateien bereitstellen

Historische Vorläufer

Hochschule RheinMain

Völlige Trennung

- Ausschließlich lokale Zugriffe
- Dateitransfer zwischen isolierten Dateisystemen (Download/Upload-Modell)
- Beispiel: UNIX uucp, ftp, rcp, scp

Adjungierte Dateisysteme

- Zugriff auf entfernte Dateien
- Explizite Angabe des Aufenthaltsorts im Dateinamen
- Beispiel: Newcastle Connection

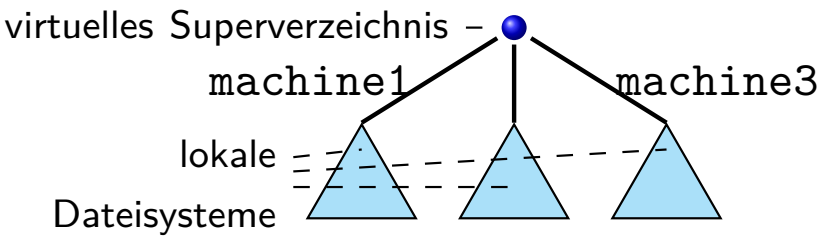


```
/machine1/<localpath>
machine2!<localpath>
/../machine3/<localpath>
```

Verteiltes Dateisystem

Hochschule RheinMain

Ein *verteiltes* Dateisystem ist ein Dateisystem, das seinen Nutzern auf allen Maschinen im Netz ein einheitliches Dateisystem zur Verfügung stellt

Mögliche Transparenzarten:

- Ortstransparenz
  - Dateiname enthält keine Ortsangabe
- Zugriffstransparenz
  - API unabhängig, ob Datei lokal oder entfernt
- Namenstransparenz
  - Dateiname an allen Stellen identisch
- Replikationstransparenz
- ...

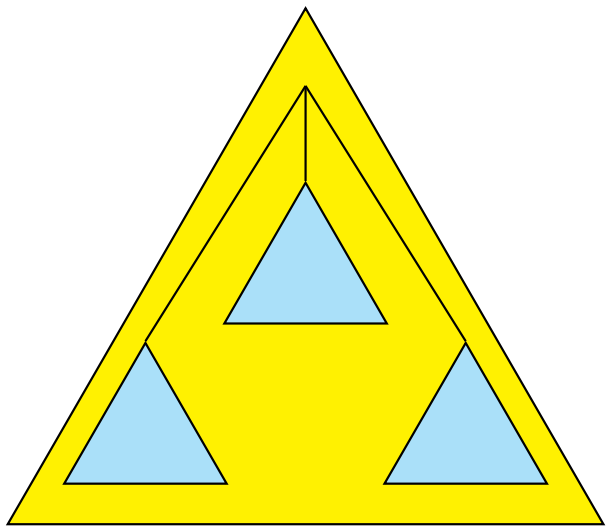

Typische Designziele

- Hohes Maß an Transparenz
  - s.o.
- Performance
  - ähnlich lokalem Zugriff
- Hohe Verfügbarkeit (Availability) / Fehlertoleranz
- Sicherheit
- Skalierbarkeit
- Unterstützung für mobile Knoten mit zeitweiser Diskonnektivität
- Unterstützung für shared disk und shared nothing (lose gekoppelte) Knoten
- Cloud-Anbindung

Lösungsüberblick

- Network File System (NFS) — ab 1985
- Andrew File System (AFS) + Coda — ab etwa 1985
- Common Internet File System (CIFS) + Server Message Block (SMB)
- GlusterFS (Gluster Inc. → Red Hat 2011)
- IBM General Parallel File System (GPFS) (ursprünglich Cluster File System, weiterentwickelt)
- Google File System (GFS)
- Apache Hadoop
- ...

Grundlagen

Hochschule RheinMain

Zugriffskonsistenzproblem

(a): Änderungen für jeden unmittelbar sichtbar und damit aktuell

(b): sichtbare Werte können veraltet sein

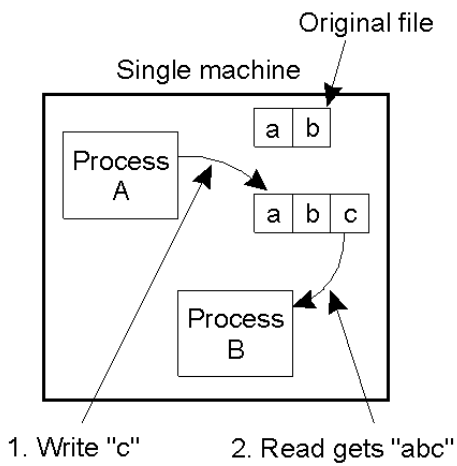

(a)

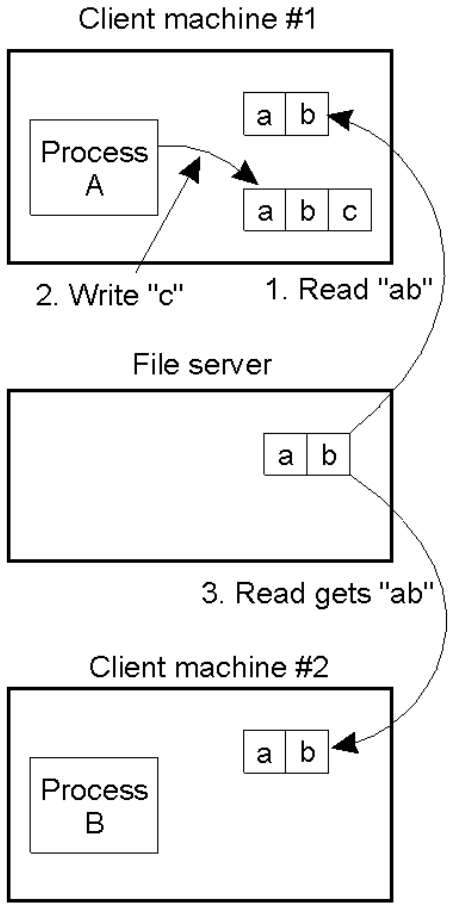

(b)

Abb. aus Tanenbaum/Steen

Semantiken

Strenge Konsistenz

- Änderungen unmittelbar für alle anderen sichtbar
- Beispiel: lokales UNIX

Sitzungssemantik

- Aktualisierung der Datei beim Schließen
- erlaubt lokalen Cache, solange Datei geöffnet ist
- Beispiel: Andrew File System

Read-Only Dateien

- Änderungen sind nicht möglich
- Gemeinsame Nutzung und Replikation werden deutlich vereinfacht

Transaktionssemantik

- Änderungen auf einer Menge von Dateien finden atomar statt (vgl. Kap. 8)

Zustandslose / zustandsbehaftete Server

Zustandlosigkeit

- Server hat kein Gedächtnis

Vorteile zustandsloser Server

- Recovery leicht realisierbar
- Keine Probleme mit Client-Abstürzen
- Öffnen / Schließen von Dateien unnötig
- Anzahl offener Dateien unbegrenzt

Vorteile zustandsbehafteter Server

- kürzere Nachrichten
- höhere Performance
- Read-ahead möglich
- Idempotenz von Operationen leichter realisierbar
- Dateisperren möglich

Replikation

Ziele

- Verfügbarkeit der Daten
- Lastausgleich
- Transparenz aus Benutzersicht

Übliche Algorithmen

- hier nicht im Detail behandelt
- Primary Copy Update
  - Primary = ausgezeichnete Kopie
  - Veränderungen nur auf Primary, dieser kümmert sich um Kopien
  - Primary sieht damit alle Updates
  - Lesen von beliebiger Kopie (Performance)
- Voting (Gifford)
  - Lese-Quorum und Schreib-Quorum haben einen nicht-leeren Schnitt
- Multiple Copy Update
  - vgl. Problematik in Datenbanken (z.B. Bernstein, Goodman, 1984)

Network File System (NFS)

Hochschule RheinMain

Designziele (1985)

- Sharing in einem Netzwerk heterogener Systeme
  - Ausgangspunkt: Diskless Workstations
- Zugriffstransparenz
  - keine speziellen Pfadnamen, Bibliotheken oder Rekompilation
- Portabilität
  - Festlegung von NFS als Schnittstelle
  - Implementierung von Client- und Server-Seite kann unterschiedlich sein
- Einfache Behandlung von Stellenausfällen
  - Zustandslosigkeit des Servers
- Performance
  - äquivalent zu lokalem Plattenzugriff
- Industriestandard
  - durch Offenlegung von Schnittstelle und Referenz-Implementierung

Gesamtarchitektur

Hochschule RheinMain

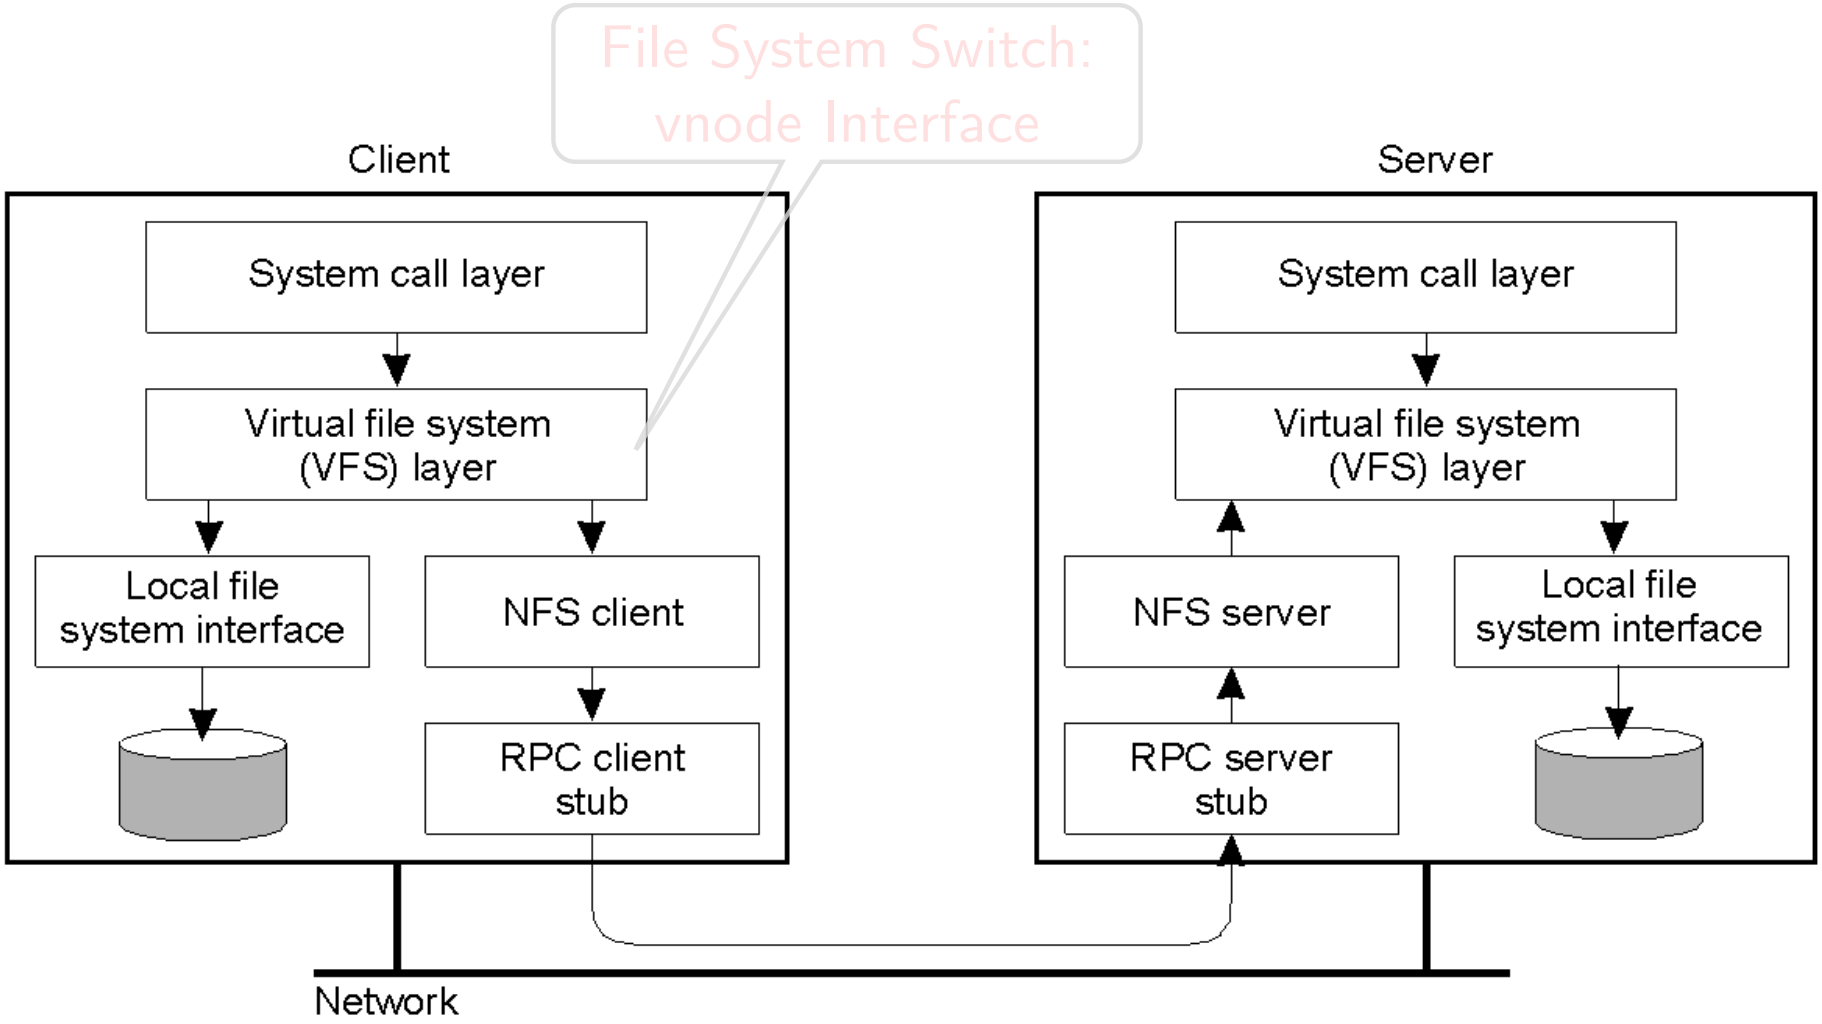

Abb. aus Tanenbaum/Steen

Gesamtarchitektur

Hochschule RheinMain

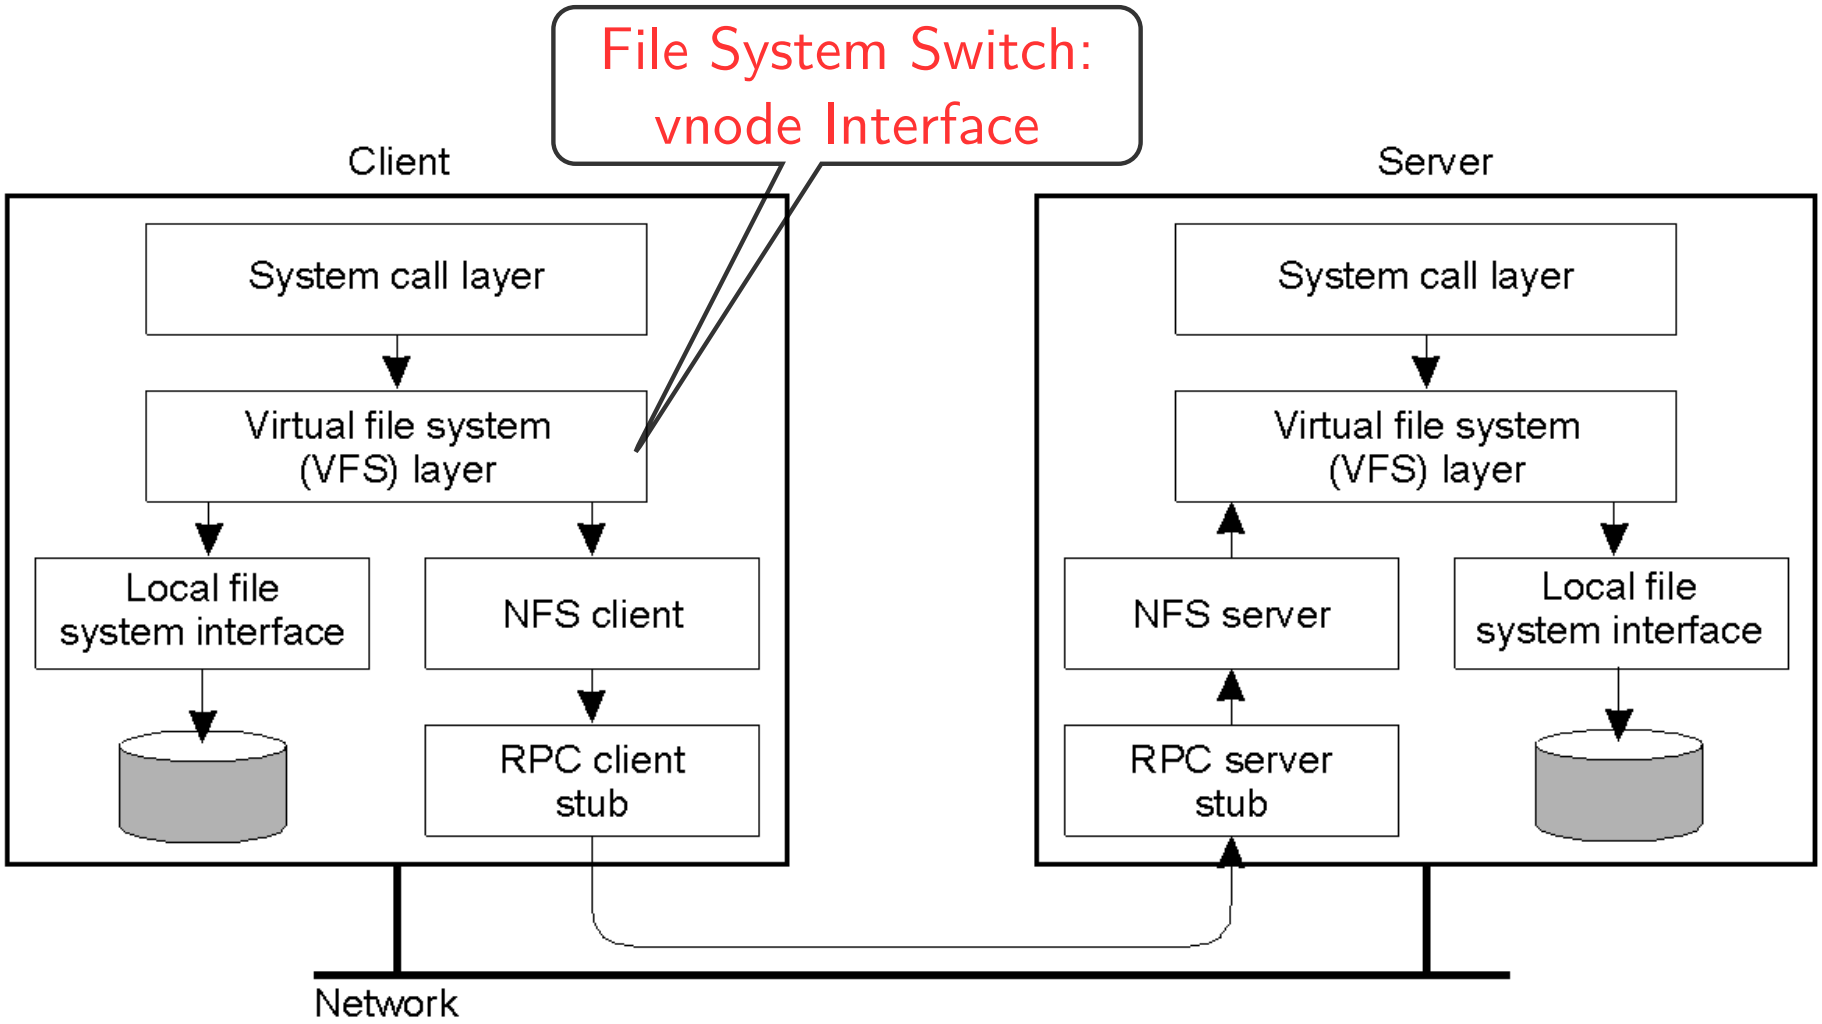

Abb. aus Tanenbaum/Steen

Funktionsweise

Rollen

- Jeder Knoten kann gleichzeitig Client und Server sein
- Jeder NFS-Server exportiert ein oder mehrere Verzeichnisse (mit dem gesamten Unterbaum)
- Gemeinsame Nutzung durch mehrere Clients möglich
- Client-Zugriff erfordert Mounting

Naming

- hierarchischer UNIX-Pfadnamensraum
- Ortstransparenz entsteht nur durch Konvention
  - nicht erzwungen
  - Mount-Punkte können prinzipiell beliebig benannt werden

Locating

- lokale Mount-Tabelle im Betriebssystem
- daher kein Protokoll zur Aufenthaltsortsbestimmung notwendig

Verzeichnisstruktur

Hochschule RheinMain

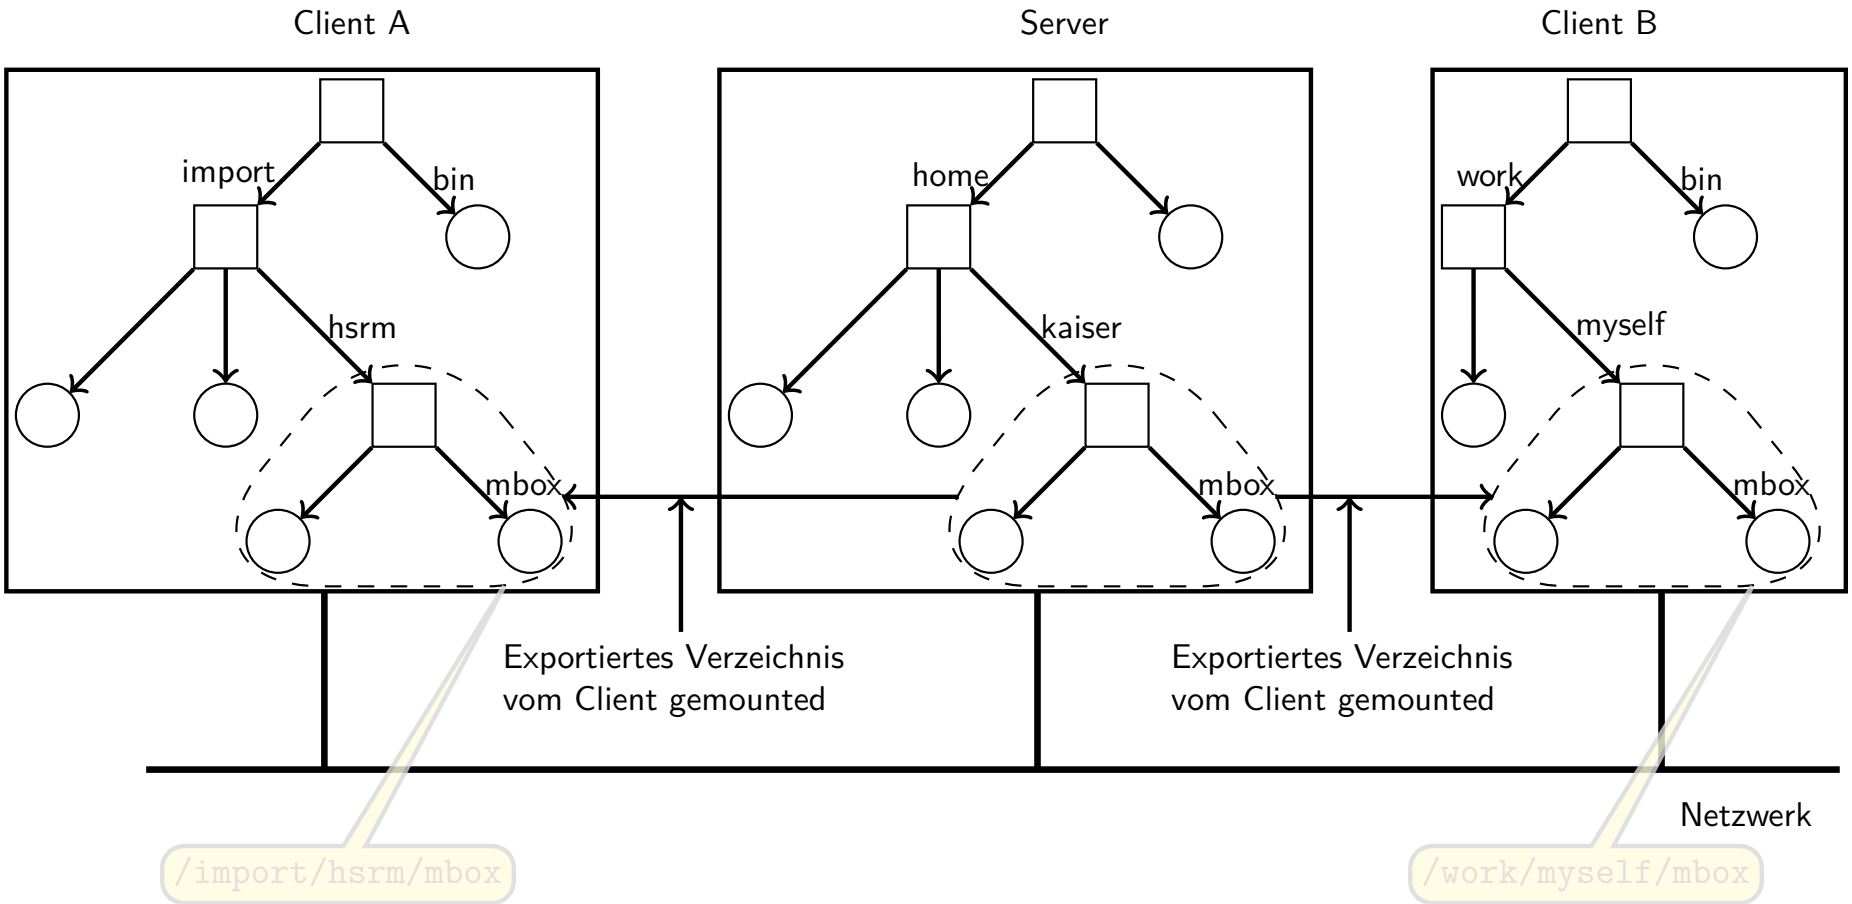

Abb. nach Tanenbaum/Steen

Verzeichnisstruktur

Hochschule RheinMain

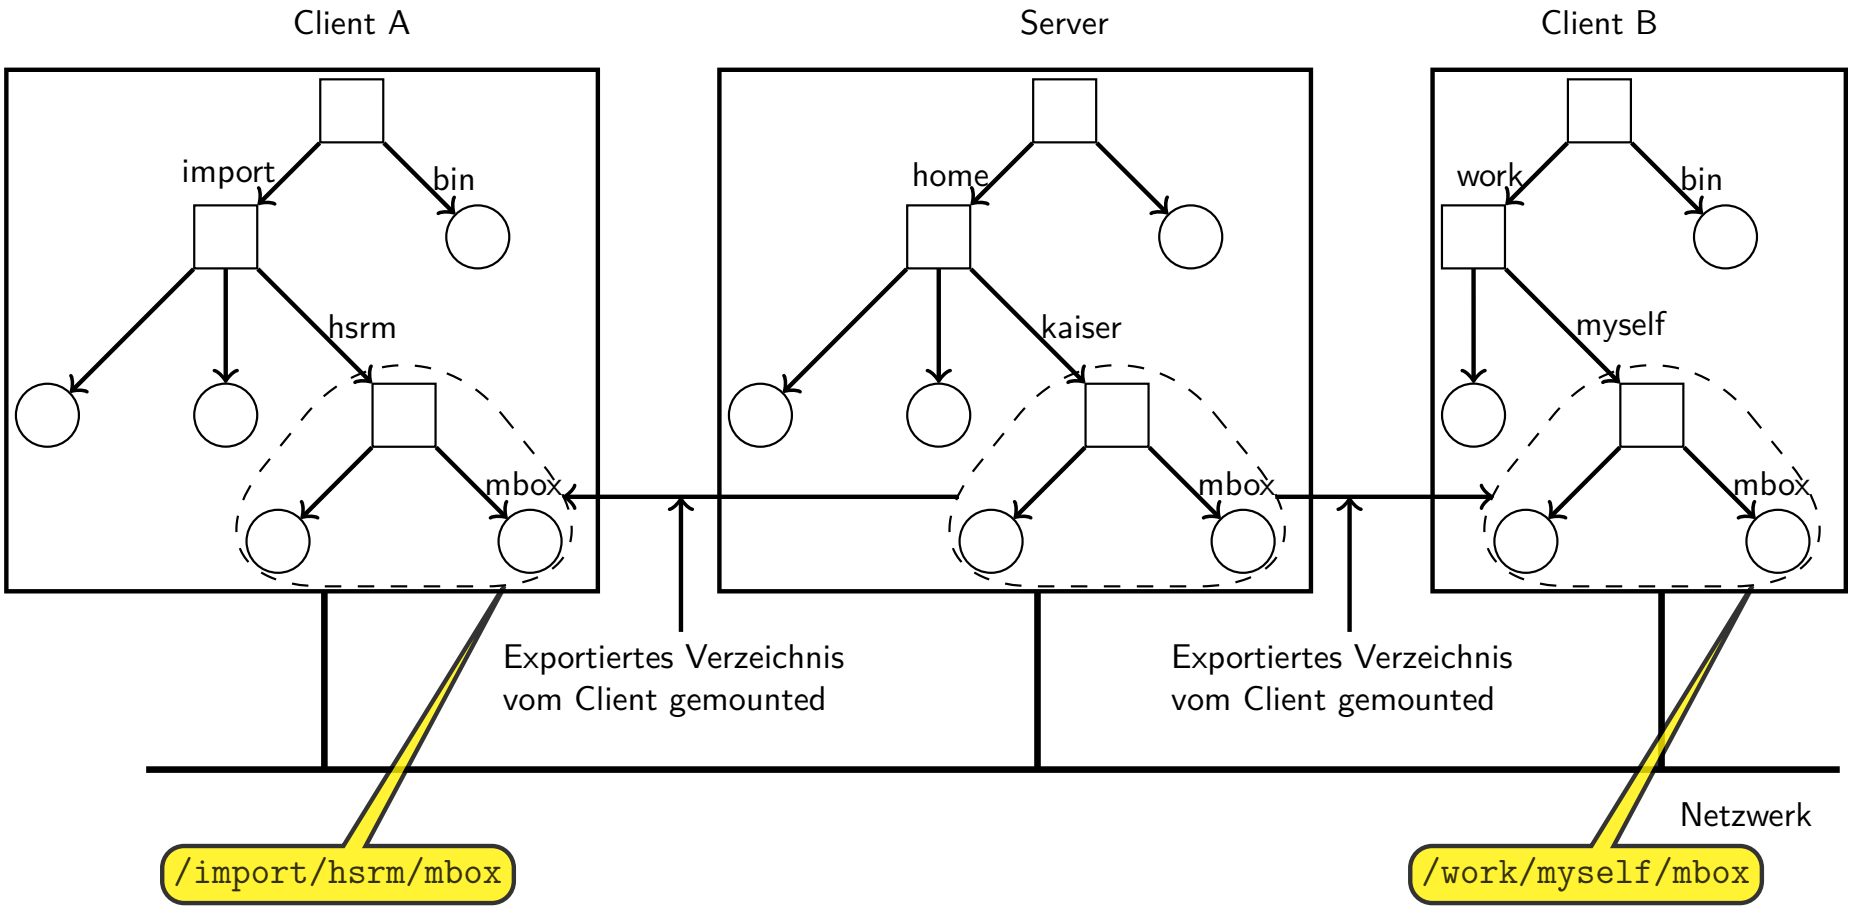

Abb. nach Tanenbaum/Steen

Mount-Protokoll

Hochschule RheinMain

- existiert bis zur aktuellen Version 3 als Teilprotokoll
- in Version 4 in allgemeines Zugriffsprotokoll integriert

- Statische Mounts
  - zum Boot-Zeitpunkt ausgeführt
- Problem:
  - u.U. nicht-verfügbarer Server zum Mount-Zeitpunkt

  → Client kann nicht ohne Probleme booten

Mount-Protokoll

Hochschule RheinMain

- existiert bis zur aktuellen Version 3 als Teilprotokoll
- in Version 4 in allgemeines Zugriffsprotokoll integriert

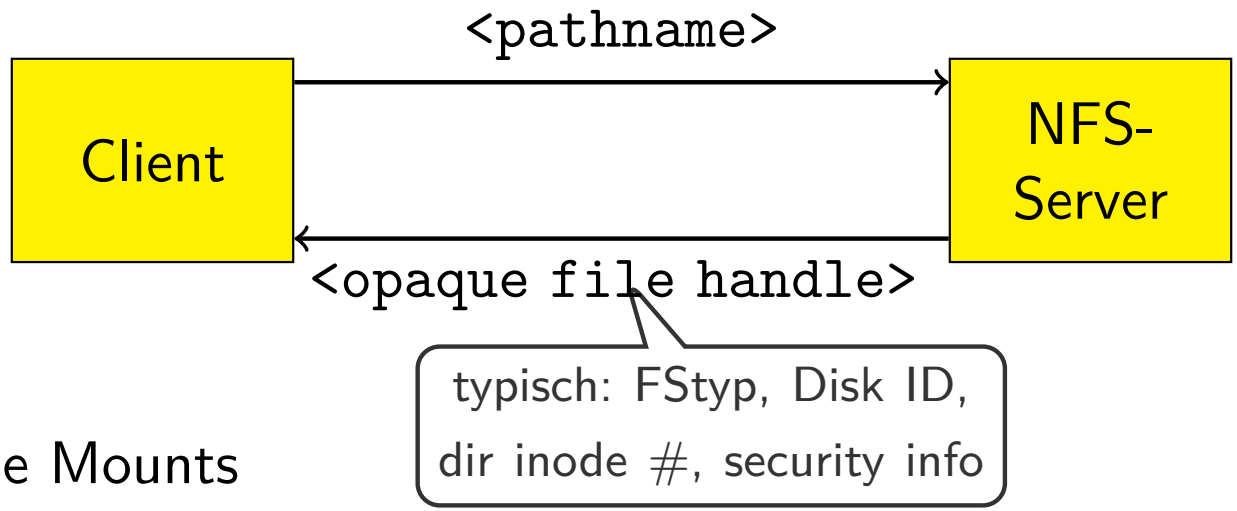

- Statische Mounts
  - zum Boot-Zeitpunkt ausgeführt
- Problem:
  - u.U. nicht-verfügbarer Server zum Mount-Zeitpunkt

  → Client kann nicht ohne Probleme booten

Automounter

Zur Lösung der Probleme statischer Mounts eingeführt
Funktionsweise

- Zuordnung:
  lokaler Mount-Punkt $\leftrightarrow$ Menge von exportierten Verzeichnissen
- Keine Aktion zum Bootzeitpunkt
- Erster Zugriff unterhalb des Mount-Punkts bewirkt Nachricht an alle Server der Menge
- Wer zuerst antwortet, wird gemountet
  - Ausgefallene Server antworten nicht und können toleriert werden
  - Lastausgleich möglich
- Keine Unterstützung für allgemeine Replikation
  - daher oft nur für read-only-Dateisysteme genutzt (z.B. `/usr`)

Zugriffsprotokoll

Für Zugriffe auf Verzeichnisse und Dateien analog UNIX system calls

Unterschiede zwischen Version 3 und neuer Version 4

- Version 3 ist zustandslos
  - keine Unterstützung für open und close
  - read/write müssen notwendige Umgebung mit anliefern (file handle, offset, nbytes)
  - keine Sperren auf Dateien, sondern in separatem Lock-Server
- Version 4 ist **nicht** zustandslos !
  - Ziel: Effiziente Nutzung von NFS in Weitverkehrsnetzen ermöglichen
  - erfordert effizientes korrektes Caching auf Client-Seite
  - geht nicht zustandslos
  - auch Dateisperren werden erlaubt

Zugriffsprotokoll (2)

Unterlagertes Protokoll

- SunRPC (ONC RPC) mit XDR-Datenkodierung
- at-least-once-Semantik
- nutzt selbst UDP/IP

Dienstschnittstelle

Hochschule RheinMain

Operation	v3	v4	Beschreibung
Create	Yes	No	Create a regular file
Create	No	Yes	Create a nonregular file
Link	Yes	Yes	Create a hard link to a file
Symlink	Yes	No	Create a symbolic link to a file
Mkdir	Yes	No	Create a subdirectory in a given directory
Mknod	Yes	No	Create a special file
Rename	Yes	Yes	Change the name of a file
Rmdir	Yes	No	Remove an empty subdirectory from a directory
Open	No	Yes	Open a file
Close	No	Yes	Close a file
Lookup	Yes	Yes	Look up a file by means of a file name
Readdir	Yes	Yes	Read the entries in a directory
Readlink	Yes	Yes	Read the path name stored in a symbolic link
Getattr	Yes	Yes	Read the attribute values for a file
Setattr	Yes	Yes	Set one or more attribute values for a file
Read	Yes	Yes	Read the data contained in a file
Write	Yes	Yes	Write data to a file

Zugriffsprotokoll (3)

Hochschule RheinMain

Zusammengesetzte Prozeduren

- Performance-Optimierung in Version 4
- insbesondere in Weitverkehrsnetzen relevant
- keine Nebenläufigkeitskontrolle oder Atomarität

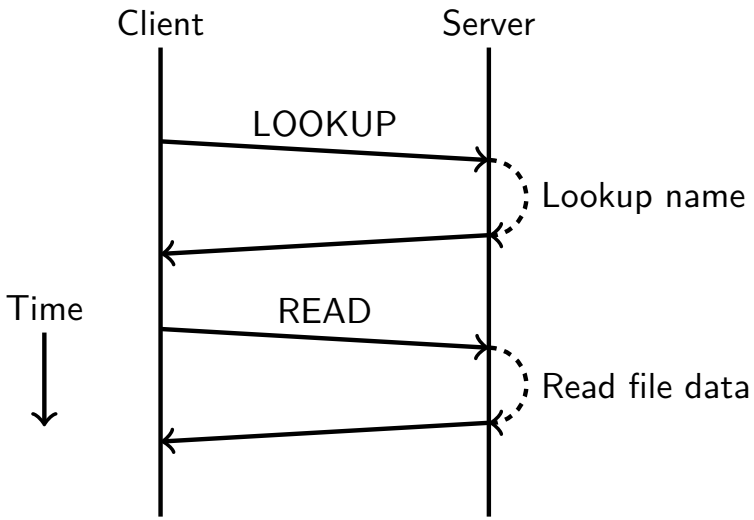

bisher in Version 3

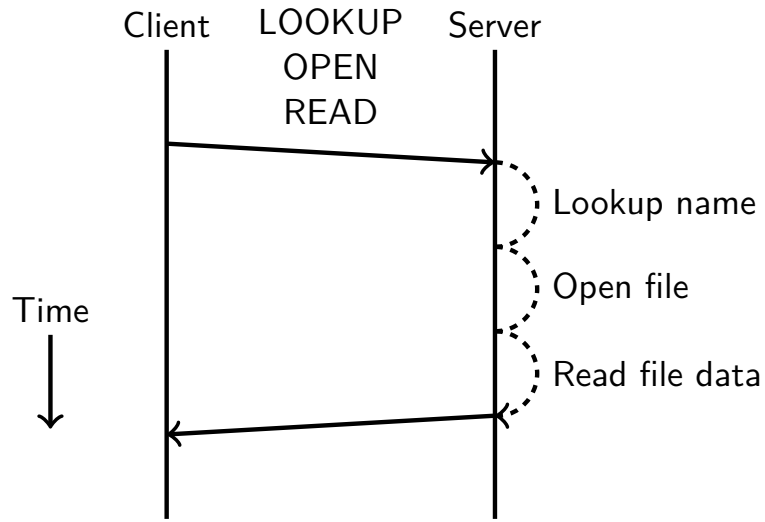

Version 4

Caching

Hochschule RheinMain

Client-seitiges Caching

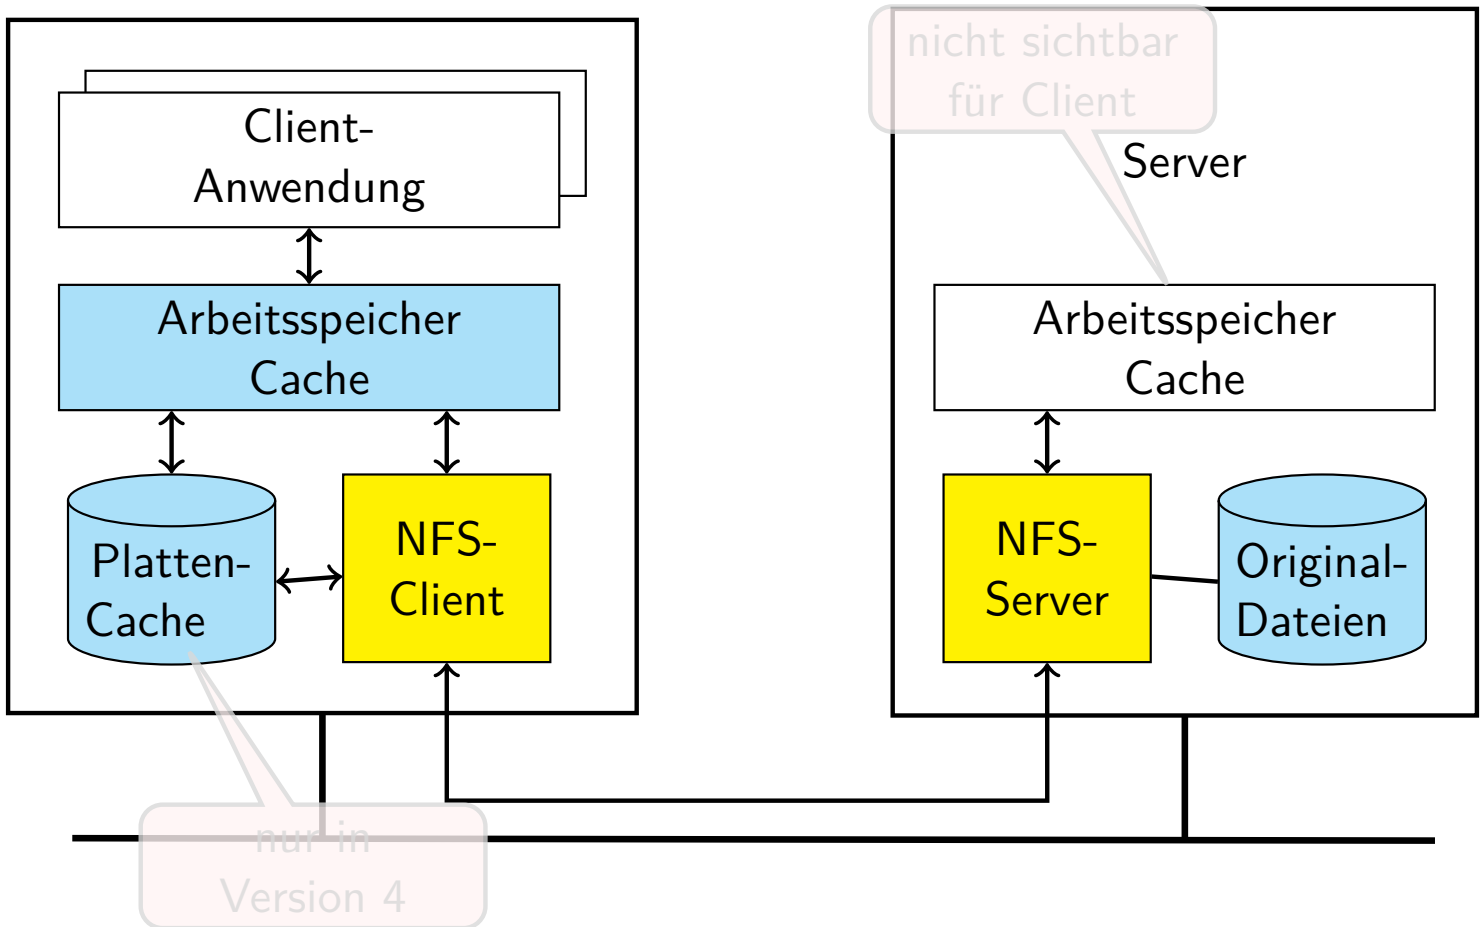

Caching

Hochschule RheinMain

Client-seitiges Caching

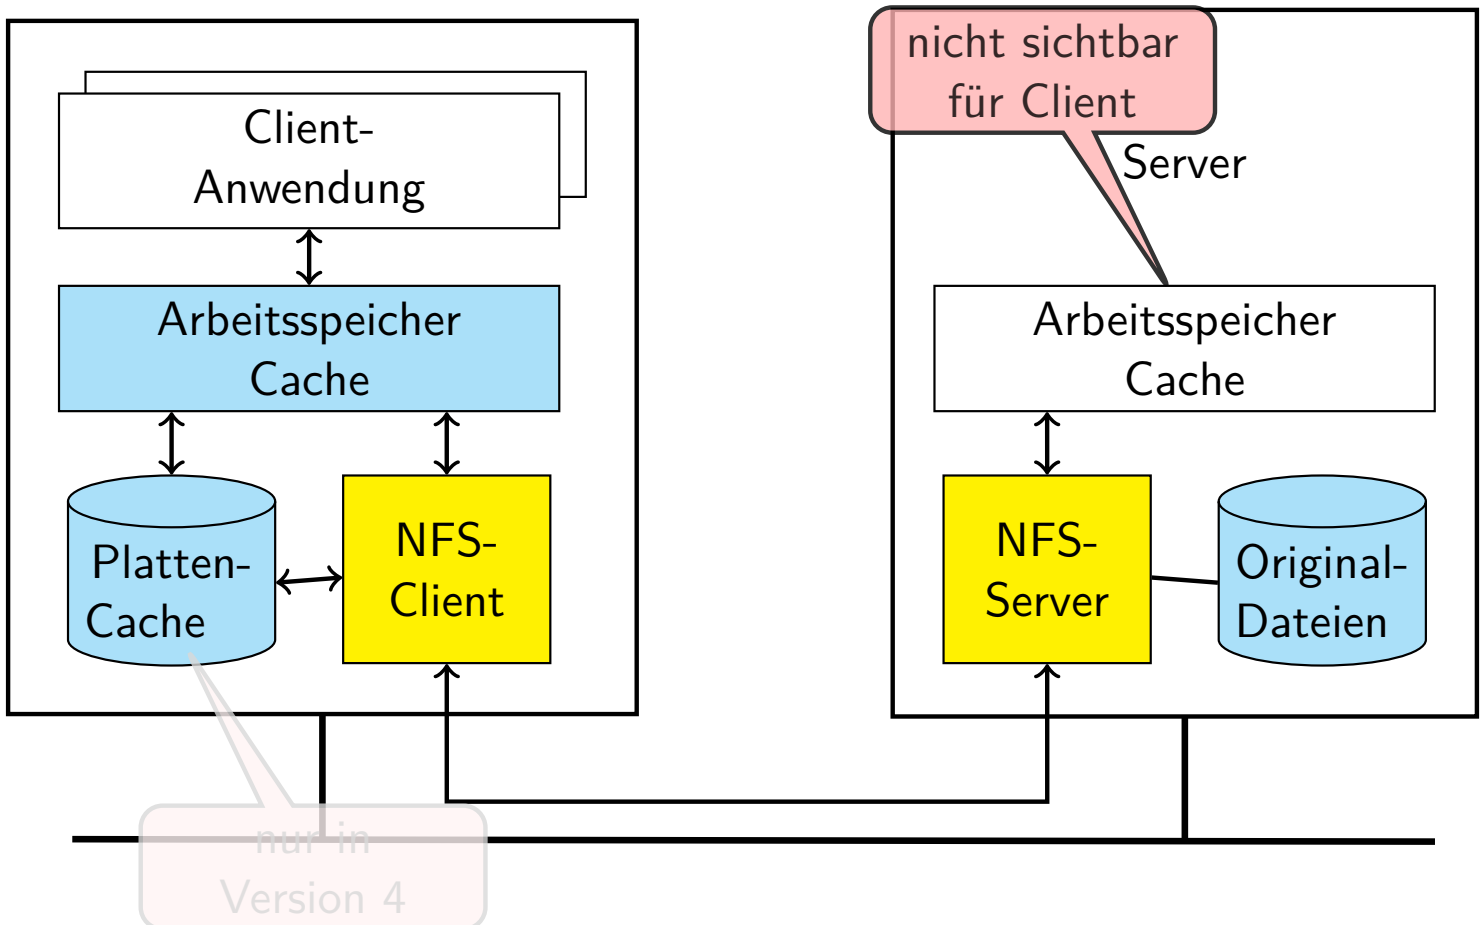

Caching

Hochschule RheinMain

Client-seitiges Caching

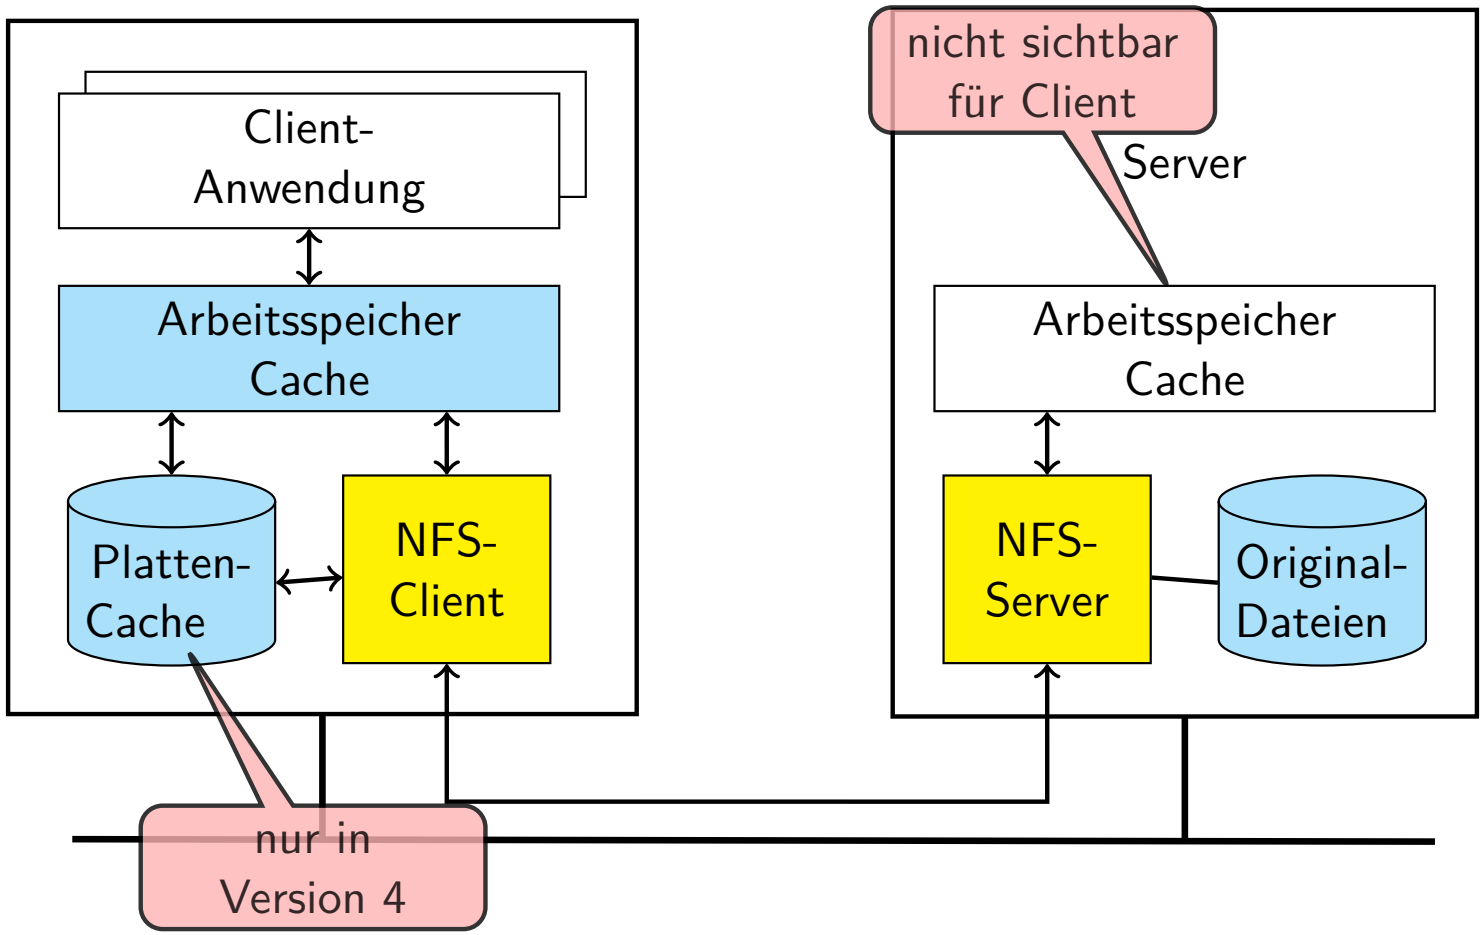

Caching (2)

Arbeitsspeicher-Cache

- Caching einzelner Blöcke entfernter Dateien
- große Blockgröße für effizienten Transfer, typisch 8 KB
- Read-ahead des nächsten Blocks
- Zugriffe auf ausführbare Dateien mit Größe $<$ Schwellwert führt zu vollständiger Übertragung

Caching (3)

Cache-Kohärenz

- in Version 3 **nicht** gegeben
  - Problem: Mehrere Clients können Blöcke derselben Datei / desselben Verzeichnisses cachen und auch modifizieren
  - zeitmarkenbasiertes unsicheres Validierungsschema
    - ★ Validierung bei `open()`, Cache Miss und Timeout (typisch: Dateien 3 Sek, Verzeichnisse 30 Sek)
    - ★ Nach Validierung wird Gültigkeit für eine Zeitspanne angenommen
    - ★ Write-Through für Blöcke von Verzeichnissen
    - ★ Alle modifizierten Blöcke werden spätestens bei `close()` an Server übertragen
  - Cache kann damit insgesamt veraltete Dateien und Verzeichnisse enthalten

  ⇒ Kooperation von Prozessen über Dateisystem unter NFS 3 nicht immer korrekt
- in Version 4 gegeben
  - Cache-Invalidierung veralteter Daten, Überprüfung bei `open()`
  - Sitzungssemantik

Caching (4)

Hochschule RheinMain

File Delegation

- nur in Version 4
- Delegation von Aufgaben des Servers an Client. Dieser überprüft `open()`- und `close()`-Operationen anderer Clients
- Möglichkeit zur Rücknahme der Delegation notwendig

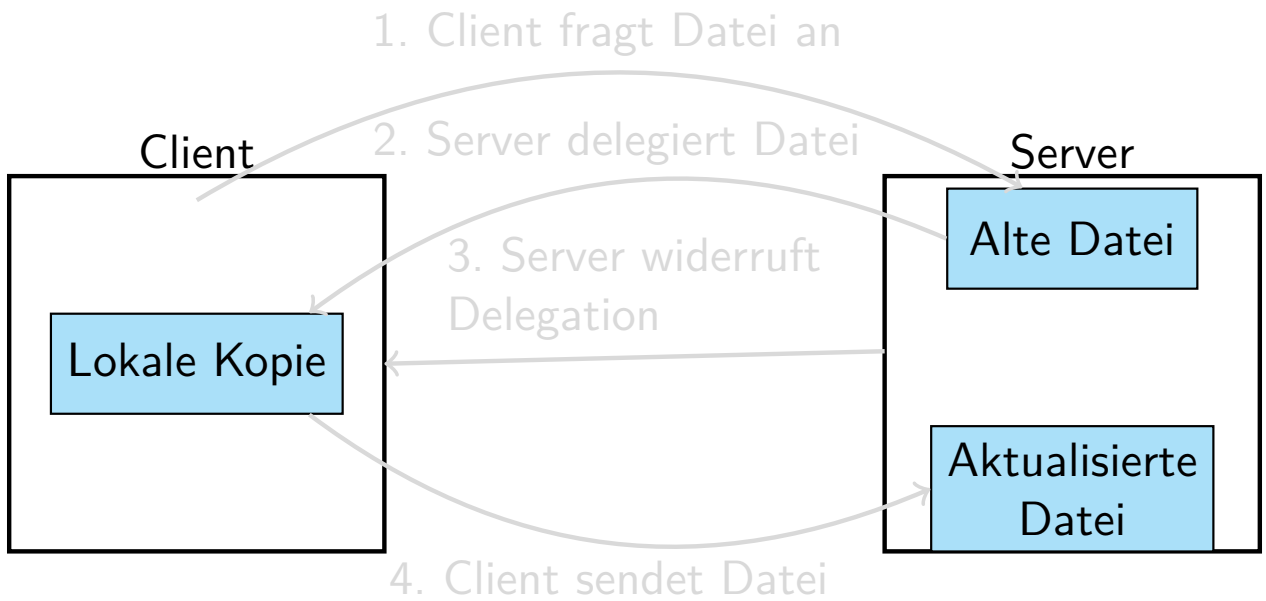

Caching (4)

Hochschule RheinMain

File Delegation

- nur in Version 4
- Delegation von Aufgaben des Servers an Client. Dieser überprüft `open()`- und `close()`-Operationen anderer Clients
- Möglichkeit zur Rücknahme der Delegation notwendig

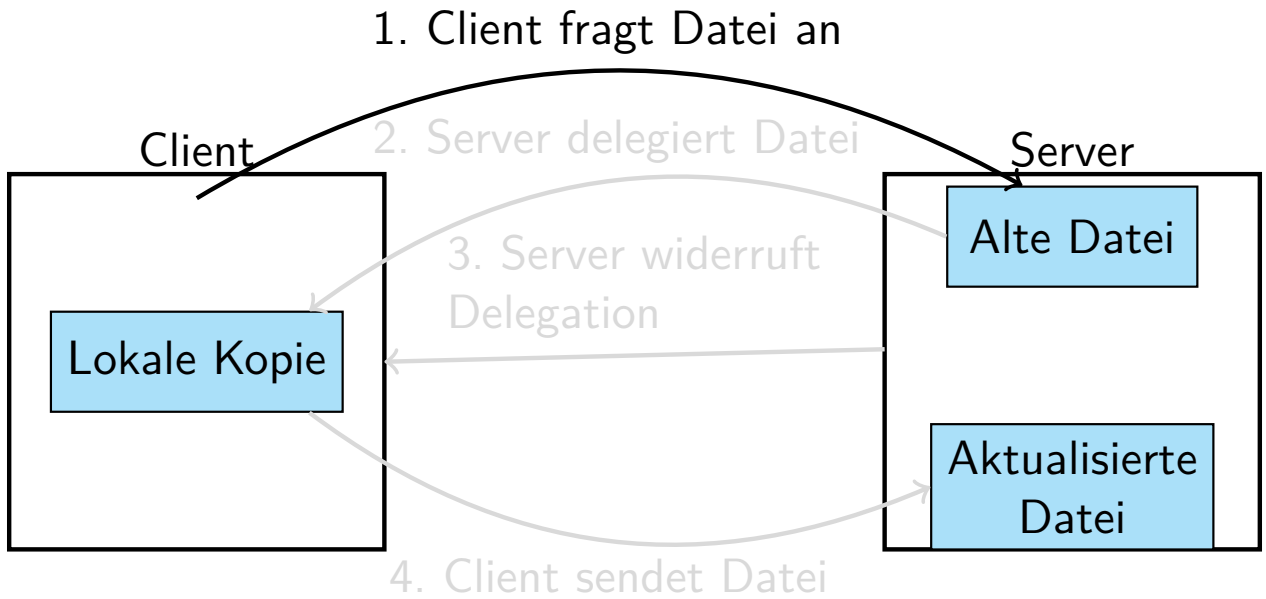

Caching (4)

Hochschule RheinMain

File Delegation

- nur in Version 4
- Delegation von Aufgaben des Servers an Client. Dieser überprüft `open()`- und `close()`-Operationen anderer Clients
- Möglichkeit zur Rücknahme der Delegation notwendig

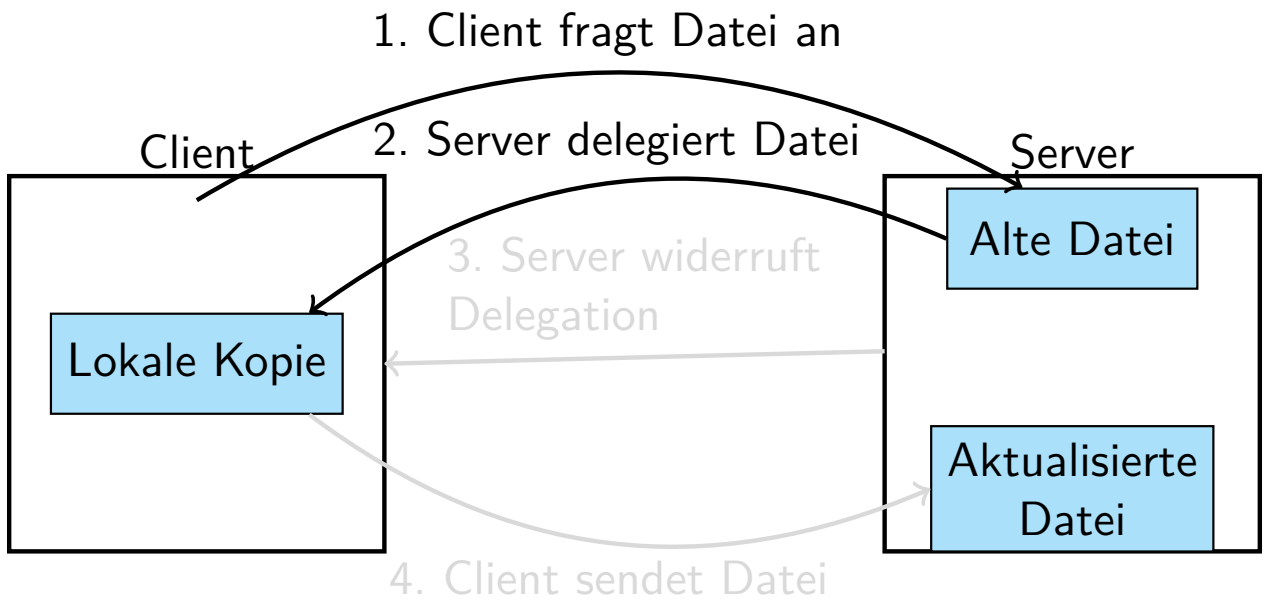

Caching (4)

Hochschule RheinMain

File Delegation

- nur in Version 4
- Delegation von Aufgaben des Servers an Client. Dieser überprüft `open()`- und `close()`-Operationen anderer Clients
- Möglichkeit zur Rücknahme der Delegation notwendig

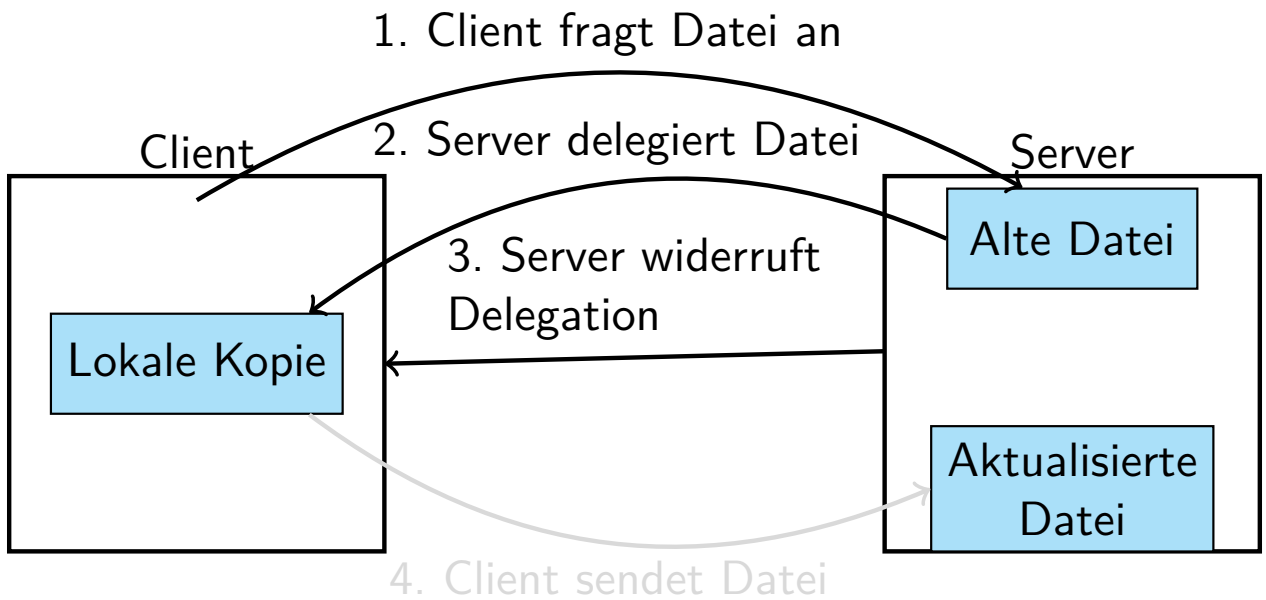

Caching (4)

Hochschule RheinMain

File Delegation

- nur in Version 4
- Delegation von Aufgaben des Servers an Client. Dieser überprüft `open()`- und `close()`-Operationen anderer Clients
- Möglichkeit zur Rücknahme der Delegation notwendig

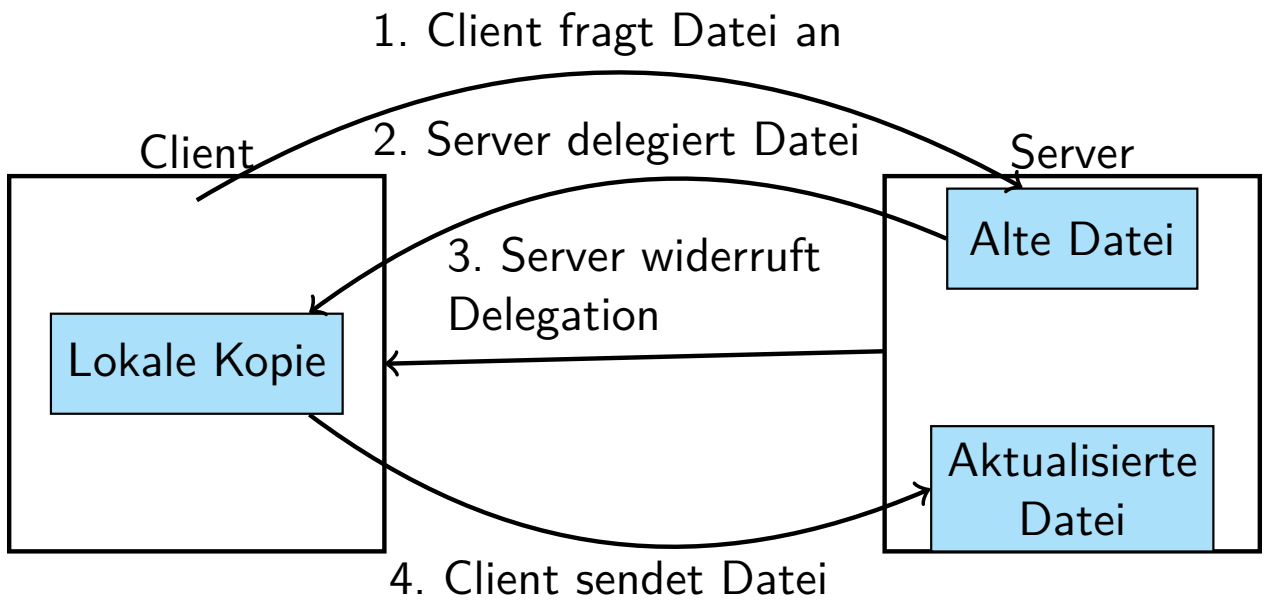

Sicherheit

Hochschule RheinMain

Prinzipielle Architektur

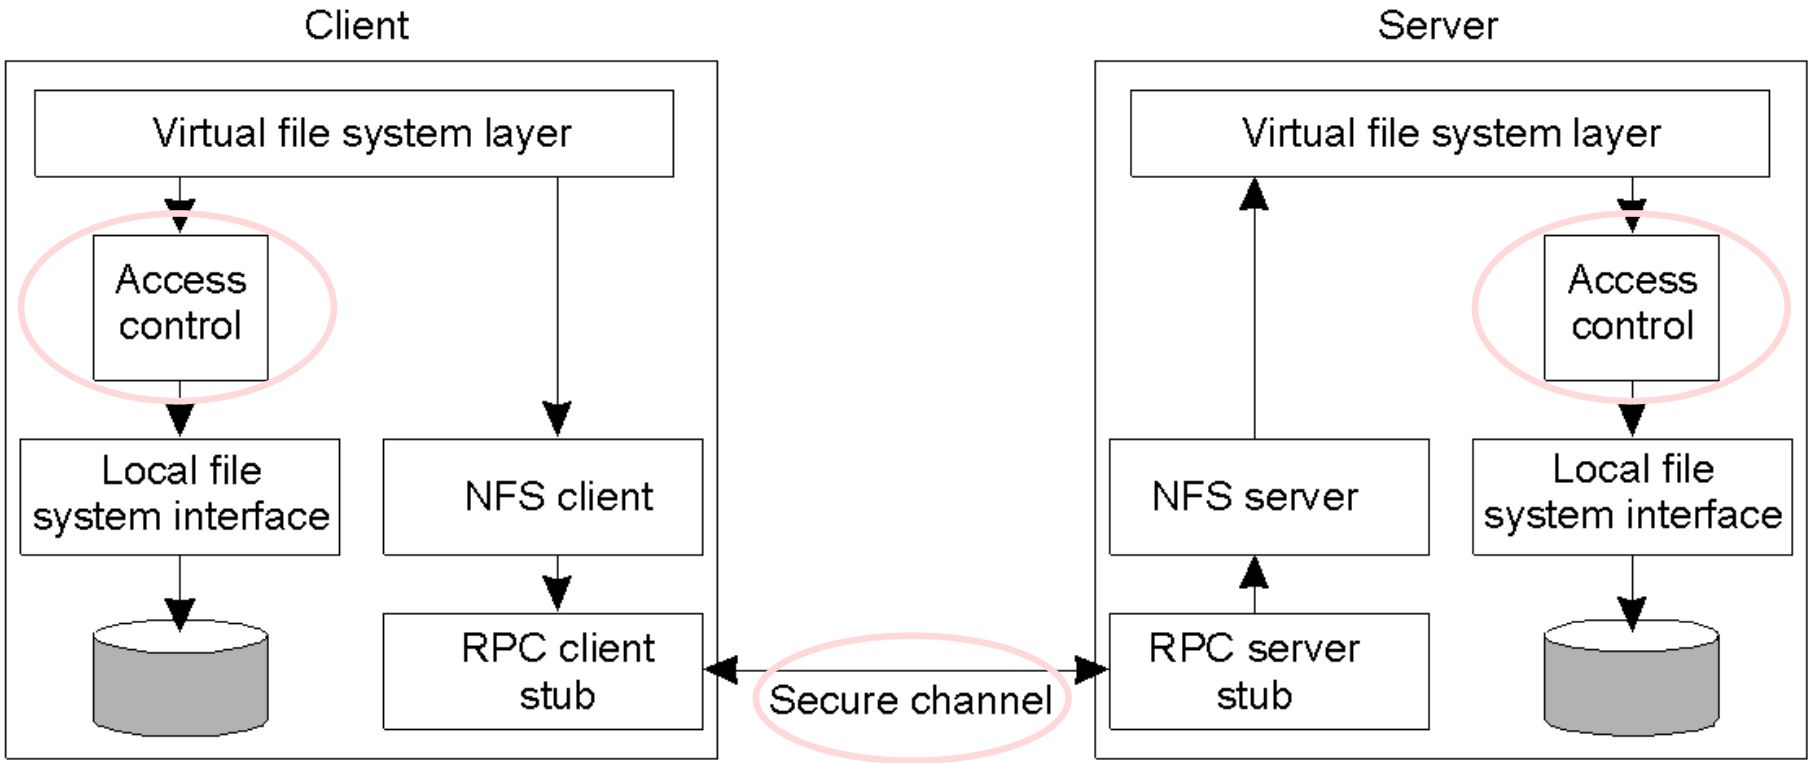

Abb. aus Tanenbaum/Steen

Sicherheit

Hochschule RheinMain

Prinzipielle Architektur

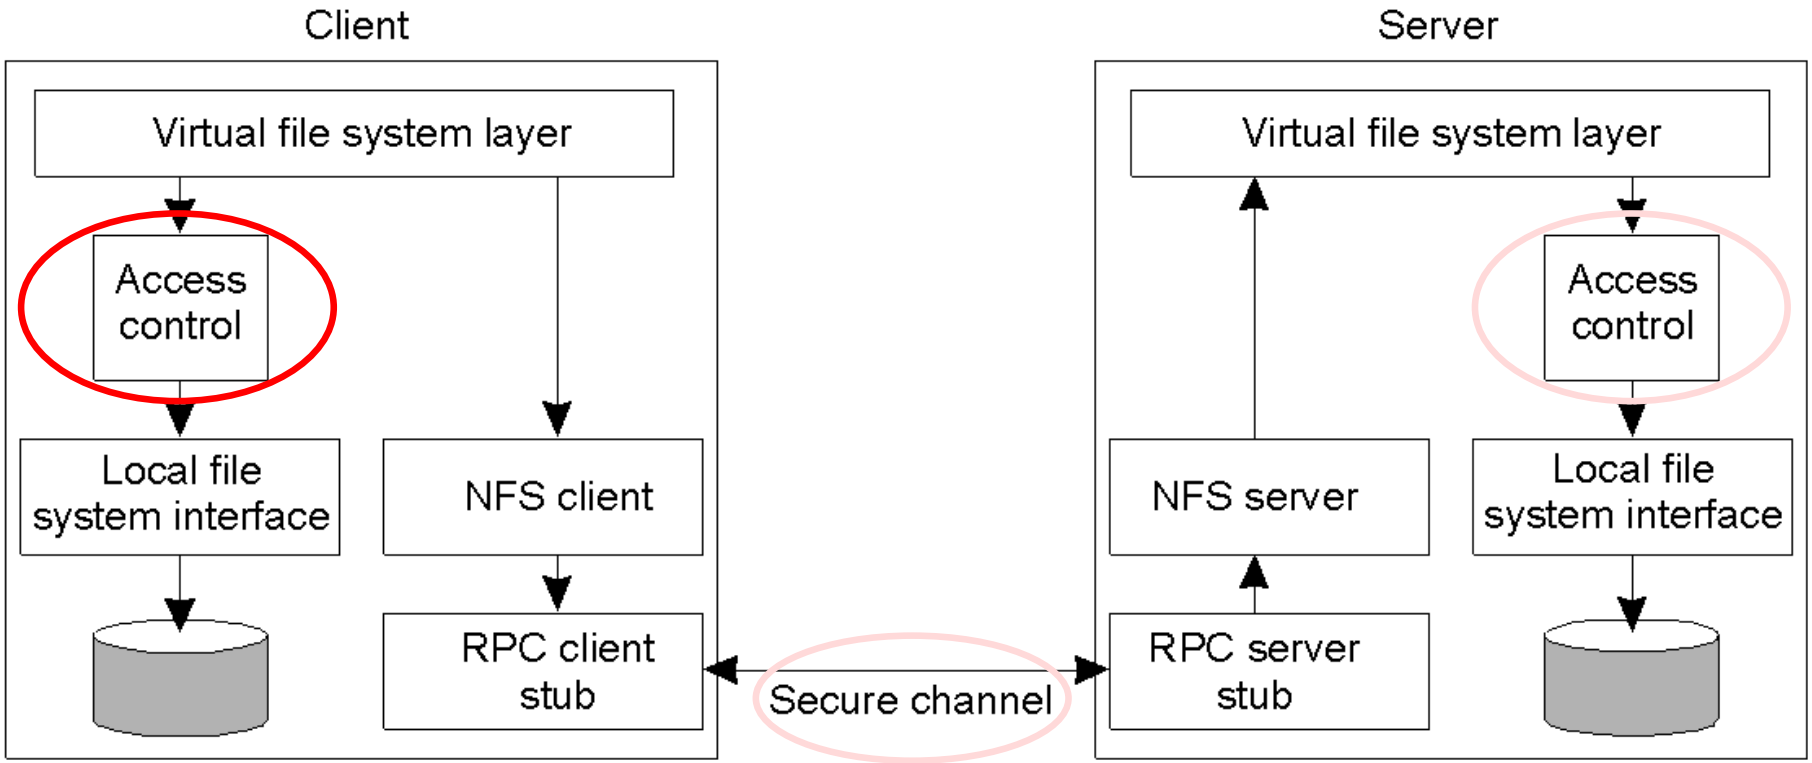

Abb. aus Tanenbaum/Steen

Sicherheit

Hochschule RheinMain

Prinzipielle Architektur

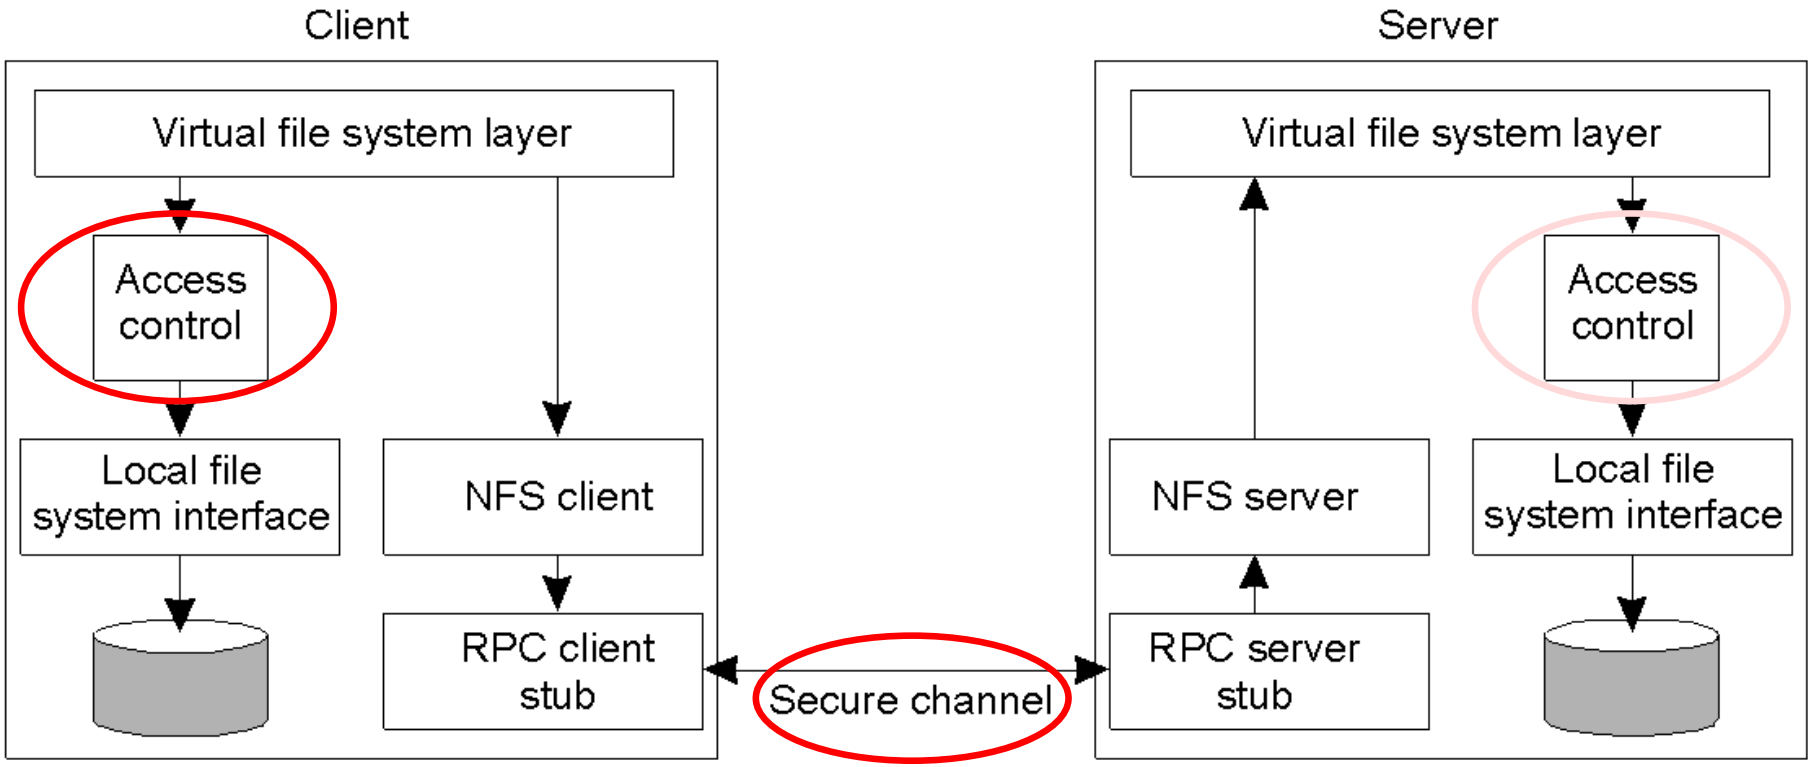

Abb. aus Tanenbaum/Steen

Sicherheit

Hochschule RheinMain

Prinzipielle Architektur

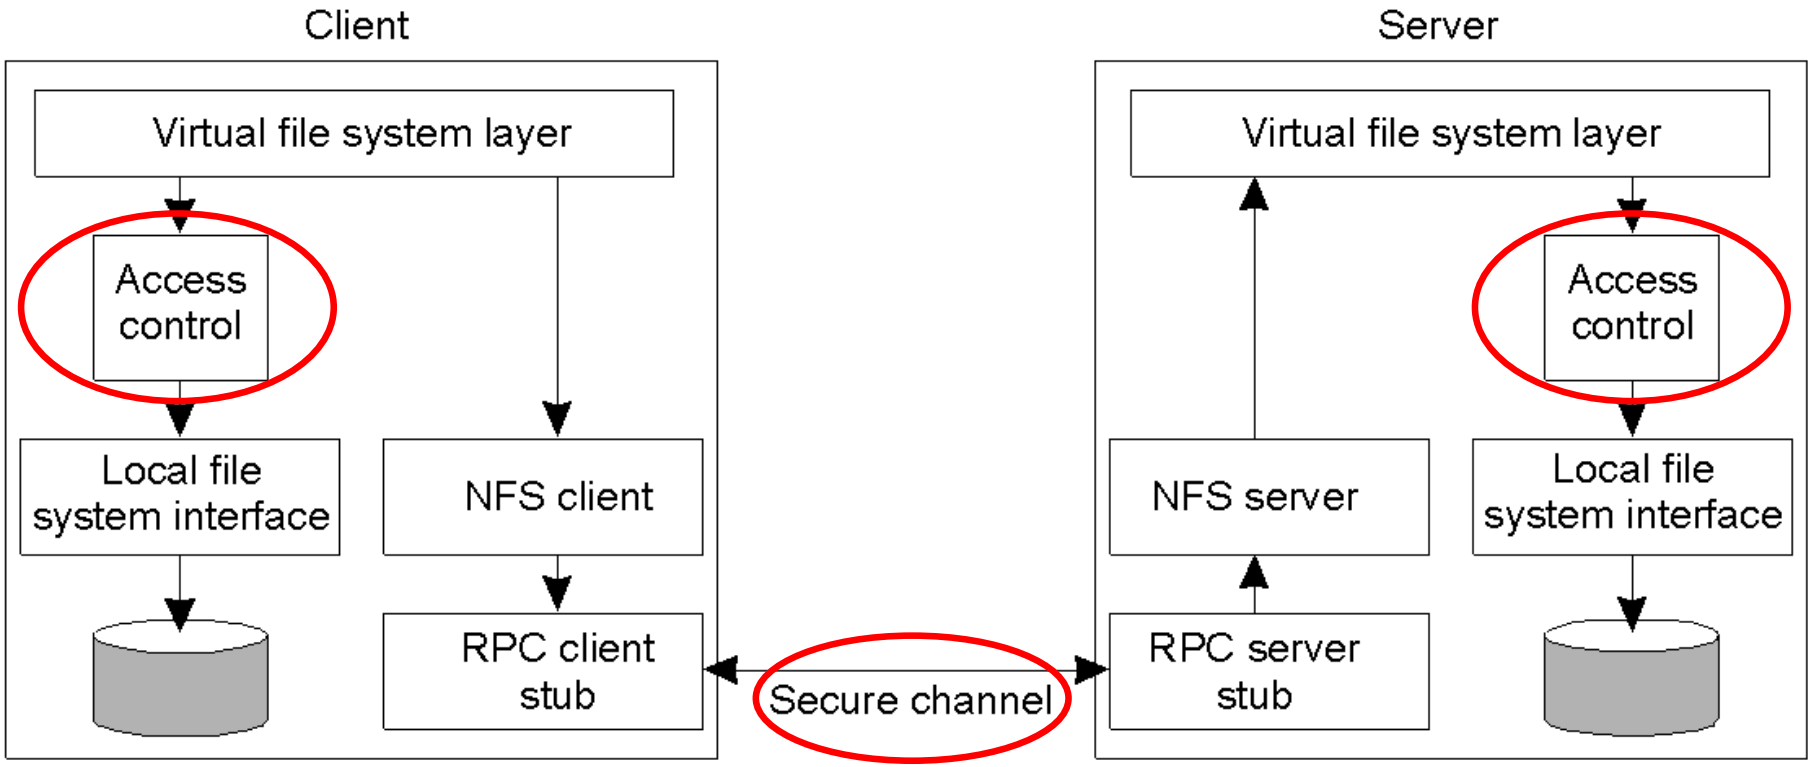

Abb. aus Tanenbaum/Steen

Sichere RPCs

Hochschule RheinMain

in Version 3:

- Nur Authentifizierung
  - „System“
    - basierend auf UNIX (uid, gid)
    - übertragen im Klartext ohne Signatur (Server traut Client)
  - Diffie-Hellman
    - selten genutzt
    - wegen zu kurzer Schlüssel heute als definitiv unsicher eingestuft
  - Kerberos

in Version 4:

- Keine eigenen, fest eingebauten Mechanismen
- Unterstützung von `RPCSEC_GSS`
  - Sicherheitsumgebung für verschiedenste einklinkbare Mechanismen
  - Neben Authentifizierung auch Integrität und Vertraulichkeit

Sichere RPCs (2)

Hochschule RheinMain

Architektur sicherer RPCs in Version 4:

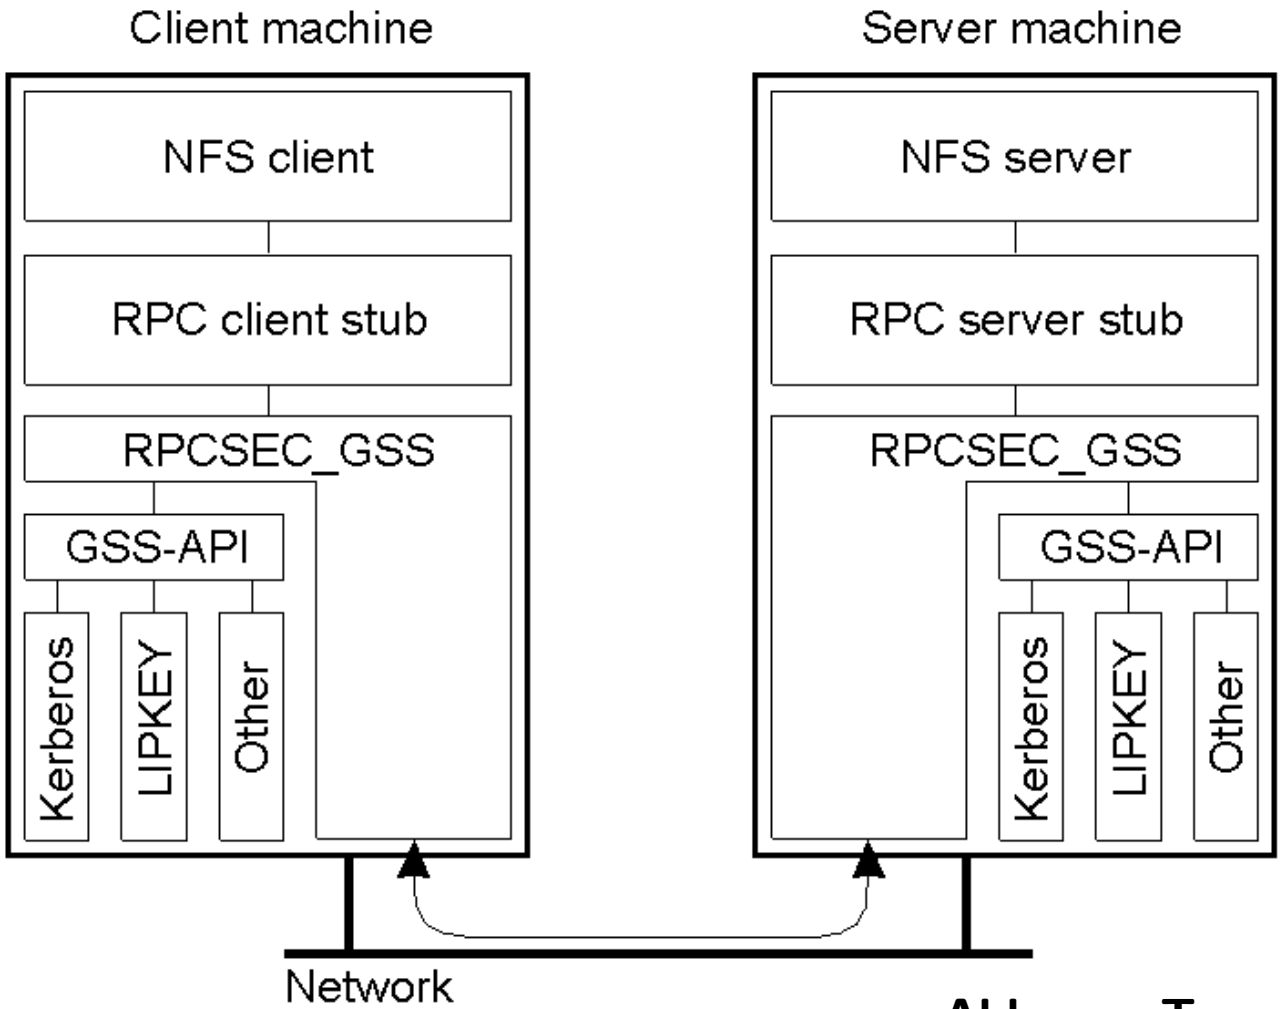

Abb. aus Tanenbaum/Steen

Zugriffskontrolle

in Version 3:

- UNIX-Rechteüberprüfung (uid, gid) auf Server-Seite

in Version 4:

- ACL-basiert
- Subjekte stark differenziert

Zugriffskontrolle (Operationen)

Operation	**Beschreibung**
Read_data	Permission to read the data contained in a file
Write_data	Permission to modify a file's data
Append_data	Permission to append data to a file
Execute	Permission to execute a file
List_directory	Permission to list the contents of a directory
Add_file	Permission to add a new file to a directory
Add_subdirectory	Permission to create a subdirectory to a directory
Delete	Permission to delete a file
Delete_child	Permission to delete a file or directory within a directory
Read_acl	Permission to read the ACL
Write_acl	Permission to write the ACL
Read_attributes	The ability to read the other basic attributes of a file
Write_attributes	Permission to change the other basic attributes of a file
Read_named_attrs	Permission to read the named attributes of a file
Write_named_attrs	Permission to write the named attributes of a file
Write_owner	Permission to change the owner
Synchronize	Permission to access a file locally at the server with synchronous reads and writes

Zugriffskontrolle (Subjekte)

Hochschule RheinMain

Benutzertyp	**Beschreibung**
Owner	The owner of a file
Group	The group of users associated with a file
Everyone	Any user of a process
Interactive	Any process accessing the file from an interactive terminal
Network	Any process accessing the file via the network
Dialup	Any process accessing the file through a dialup connection to the server
Batch	Any process accessing the file as part of a batch job
Anonymous	Anyone accessing the file without authentication
Authenticated	Any authenticated user of a process
Service	Any system-defined service process

Nach Tanenbaum/Steen

AFS und Coda

Hochschule RheinMain

Andrew File System (AFS)

- CMU zusammen mit IBM, 1983-1989, danach Transarc
- Dateisystem für den Campus mit $>$ 5.000 aktiven Studenten
- Ziele
  - Ortstransparenter, globaler, gemeinsam genutzter Dateinamensraum, erreichbar über den lokalen Namen /afs
  - Hohe Performance
  - Hohe Verfügbarkeit
    - ★ Replikation
  - Hohe Sicherheit
    - ★ Gesicherte Authentifikation
    - ★ Verschlüsselte Übertragung
    - ★ ACLs zur Zugriffskontrolle
  - Automatische Migration von Home-Verzeichnissen von Benutzern

Coda

- Weiterentwicklung von AFS-2

Dateinamensraum

Hochschule RheinMain

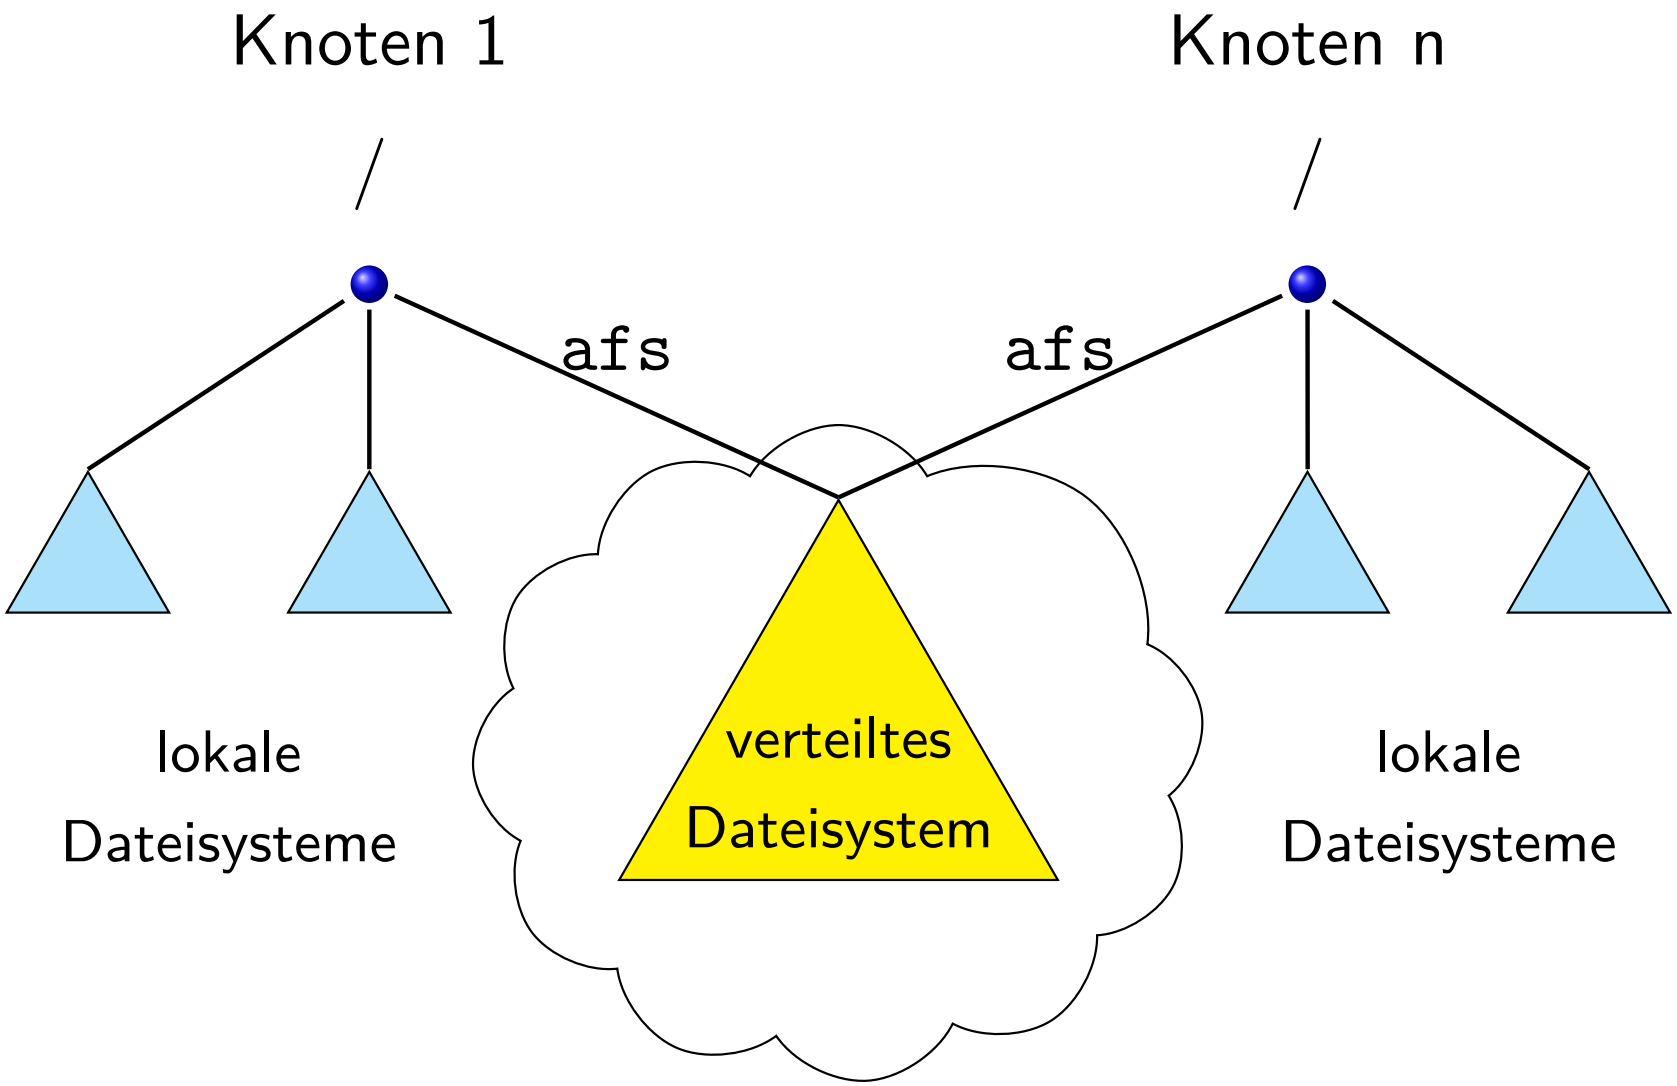

Gesamtarchitektur

Hochschule RheinMain

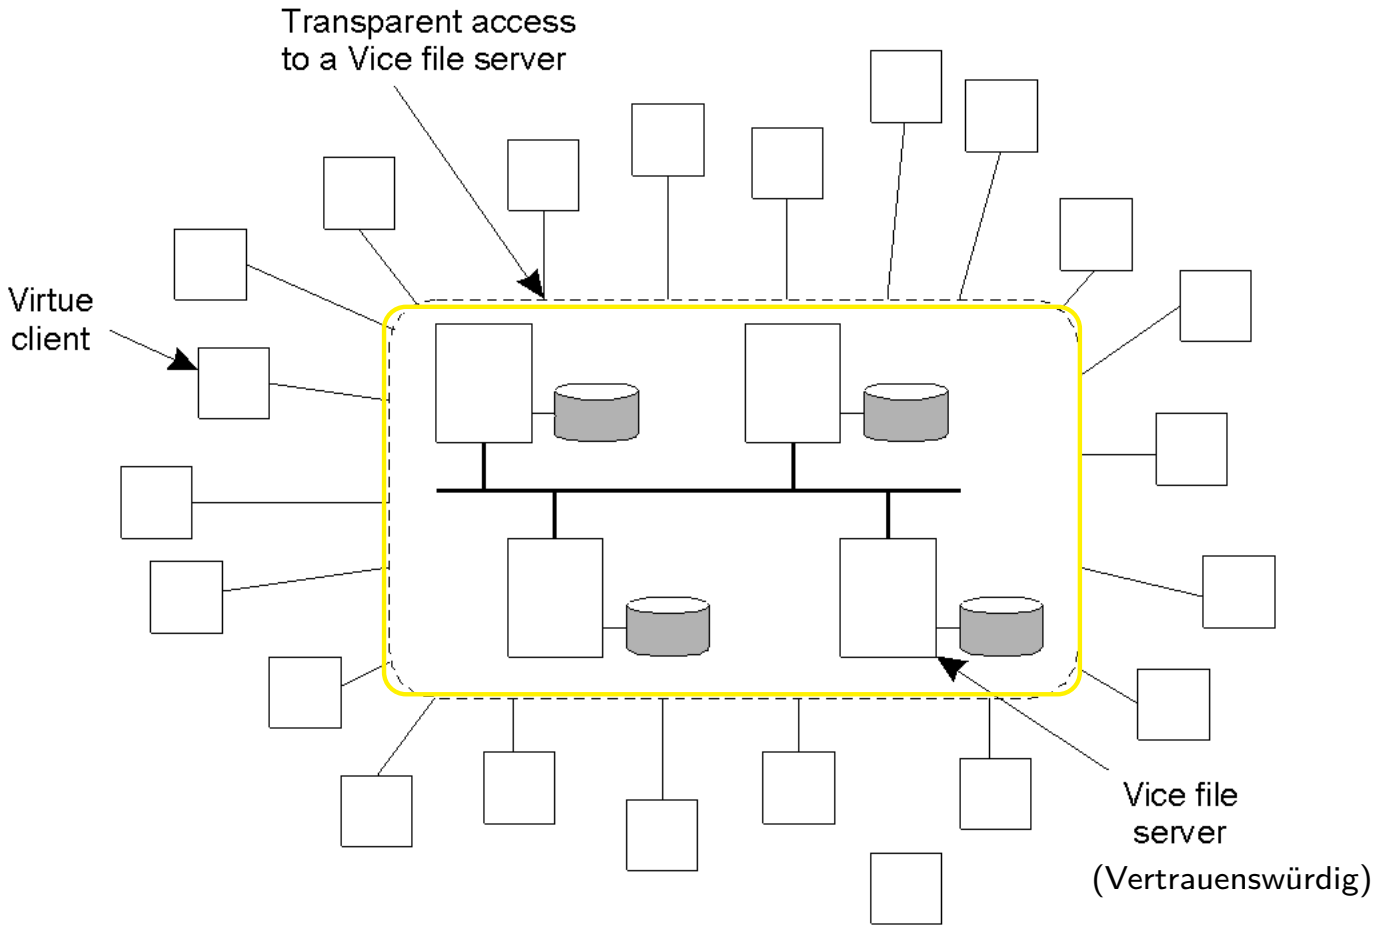

Abb. aus Tanenbaum/Steen

Volumes

Hochschule RheinMain

Mountbare Volumes

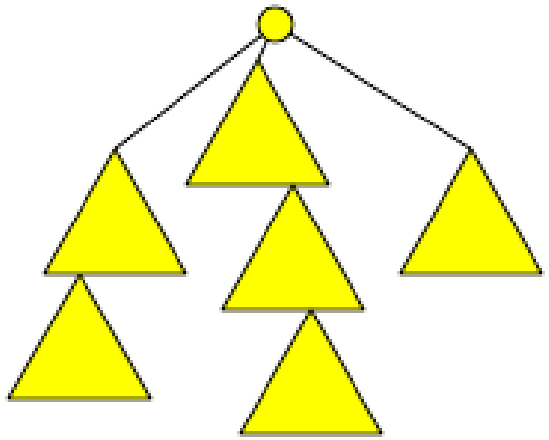

Struktur des globalen Dateiraums in Vice

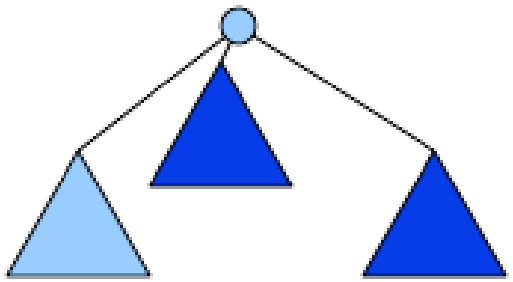

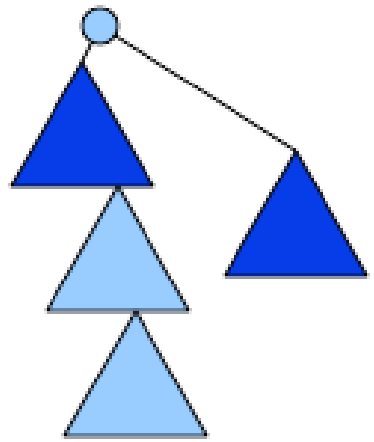

reale Struktur in den Knoten (Teilgraph)

Knoten 1

Knoten n

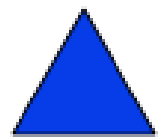

repliziert

Architektur eines Virtue-Clients

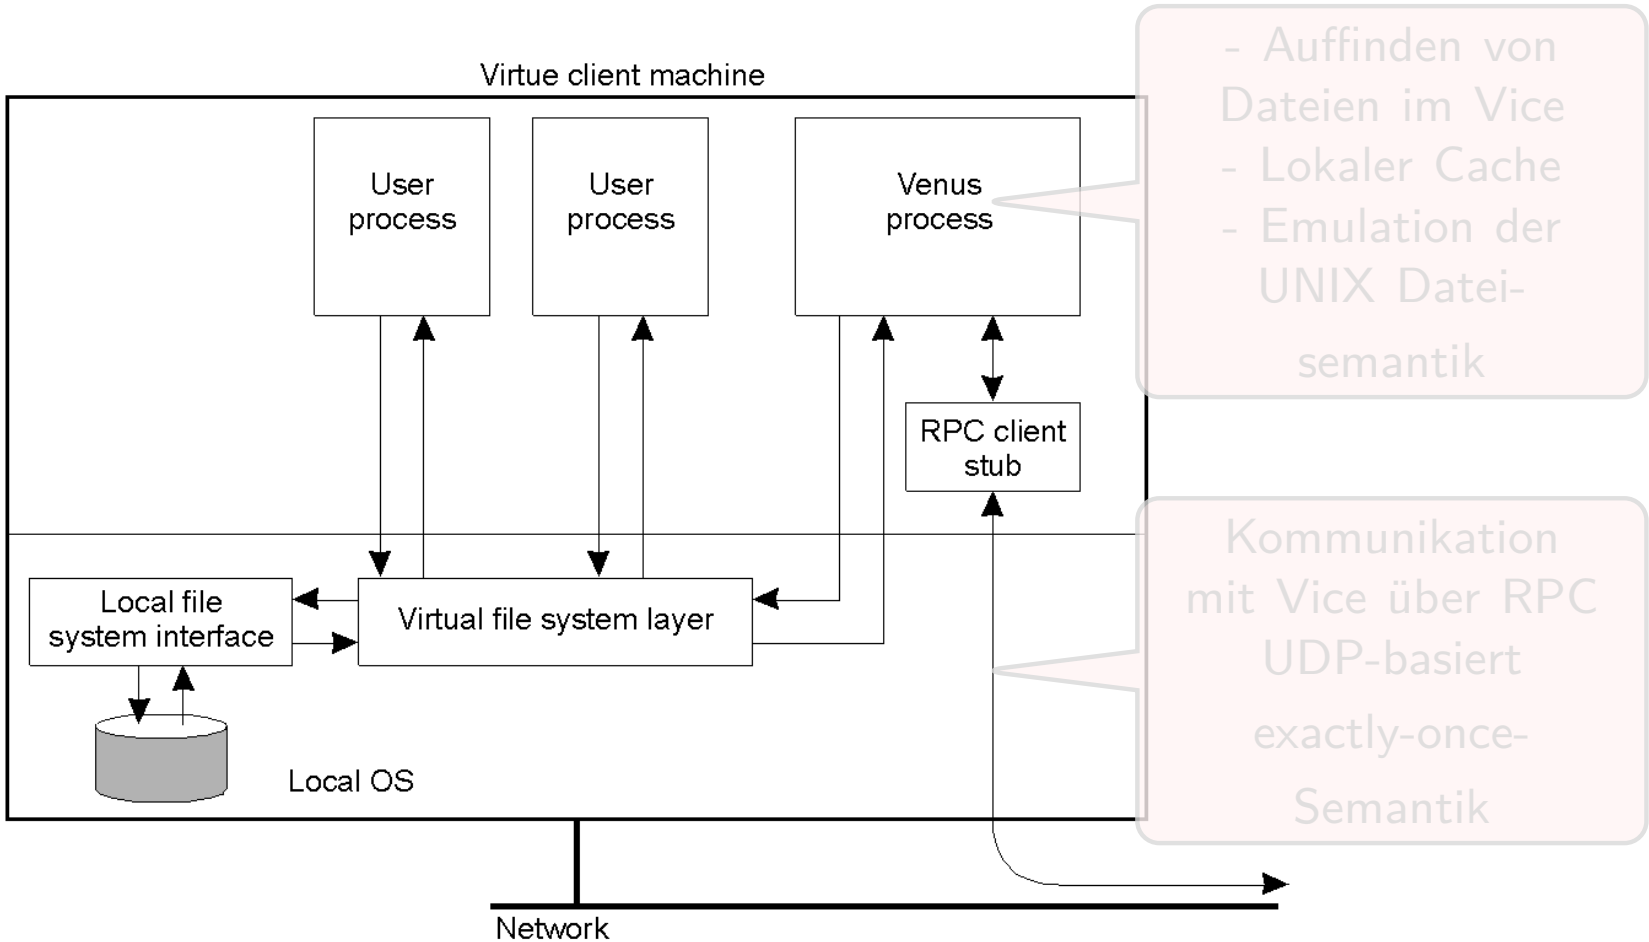

Abb. aus Tanenbaum/Steen

Architektur eines Virtue-Clients

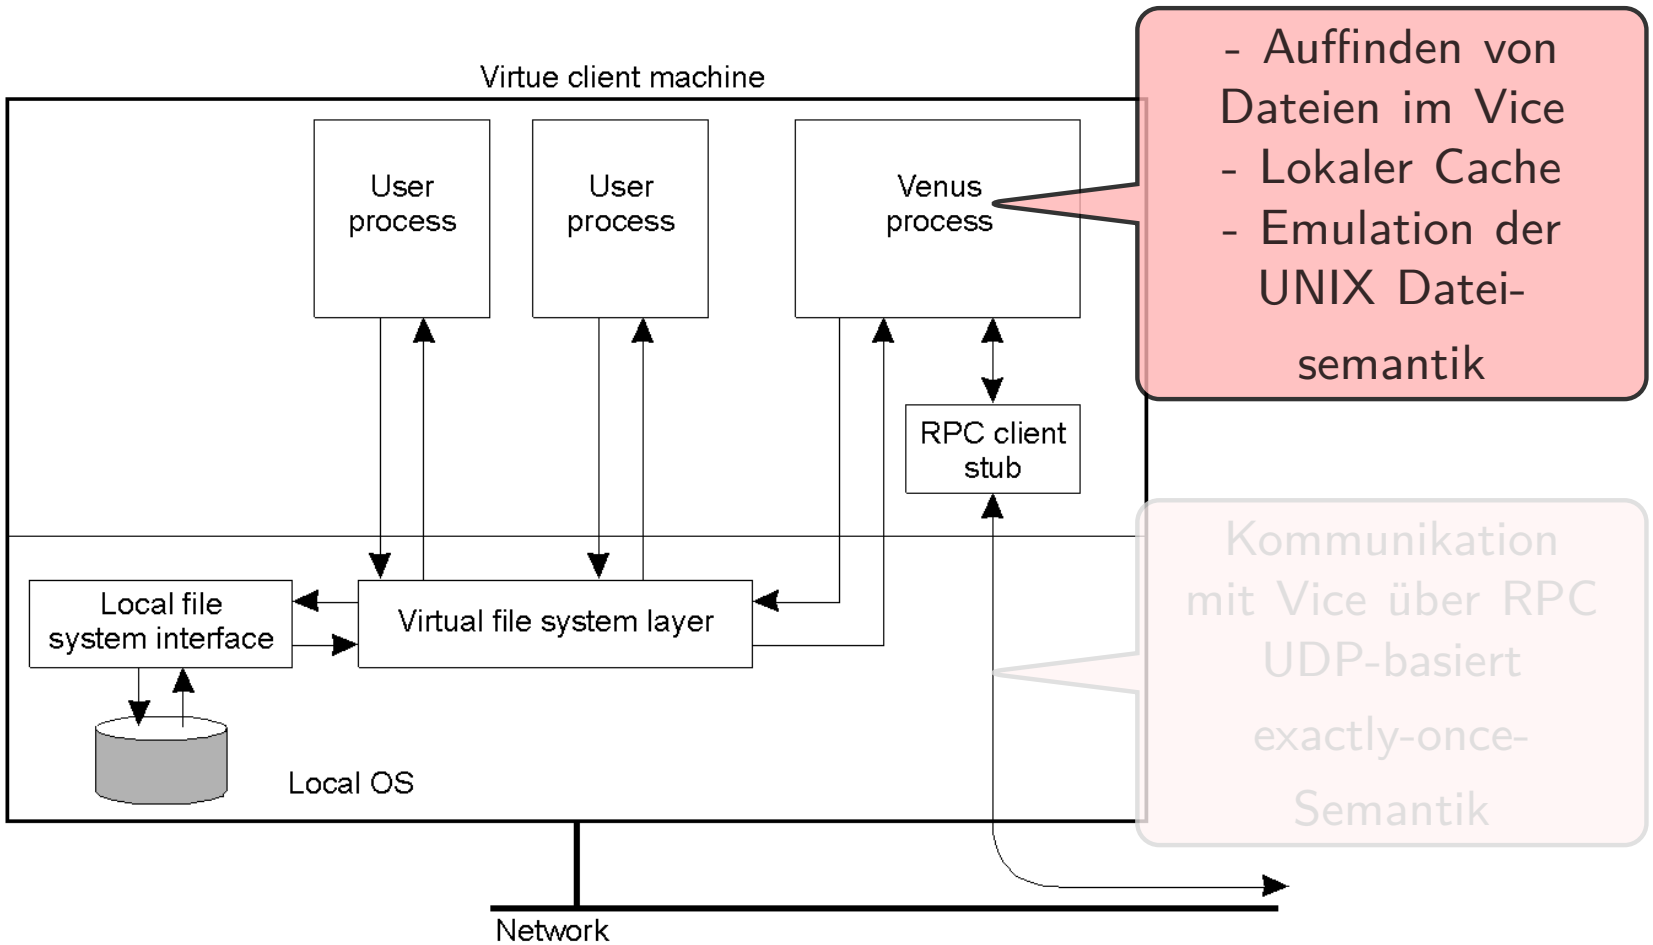

Abb. aus Tanenbaum/Steen

Architektur eines Virtue-Clients

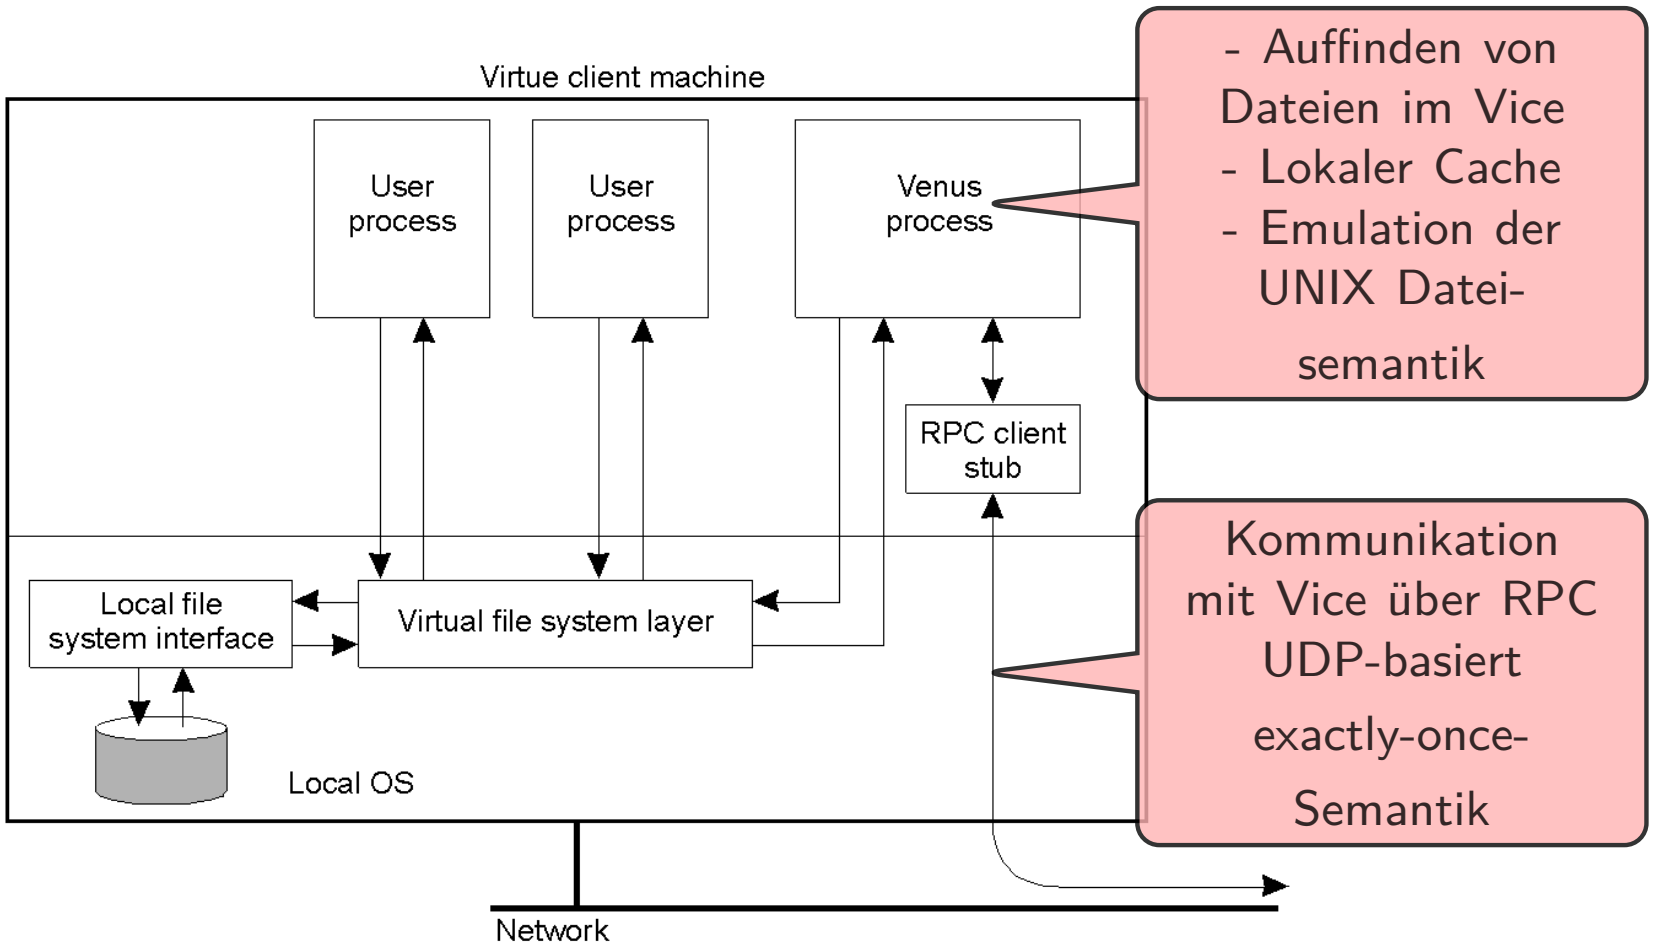

Abb. aus Tanenbaum/Steen

Eigenschaften

- gemeinsam genutzte Dateien mit Sitzungssemantik
- Lokales Caching von ganzen Dateien bis AFS-2, von großen Dateiblöcken (64 kB) ab AFS-3
- Cache-Kohärenz
  - Überprüfen der Gültigkeit des Caches nicht bei jedem `open()` notwendig
  - Callback-Verfahren, d.h. explizites Invalidieren durch den Server, bevor ein anderer Client Schreibrecht bekommt.

Sicherheit

- Organisation
  - Vice-Server sind vertrauenswürdig
  - keine Benutzer-Anwendungen auf Servern
  - Einführung administrativer Zellen zur Erhöhung der Skalierbarkeit
- Subjekte
  - Benutzer
  - Gruppen
- Authentifizierung
  - spezielle Authentication Server, Kerberos (ab AFS-3)
  - sicherer RPC
- Zugriffskontrolle
  - ACLs für Verzeichnisse definiert, gelten für alle Dateien des Verzeichnisses

Coda

- Weiterentwicklung von AFS-2 ab 1987
- Ziele:
  - Hohe Verfügbarkeit der Daten
  - Client soll weiterarbeiten können, auch wenn Server vorübergehend nicht erreichbar ist (Netzpartitionierung)
  - Einbeziehung von mobilen Rechnern (gewollte Netzpartitionierung)

Kommunikation

Hochschule RheinMain

RPC2-System

- Nutzung von internem Multithreading für Venus und Vice
- Unterstützung von sog. Nebeneffekten

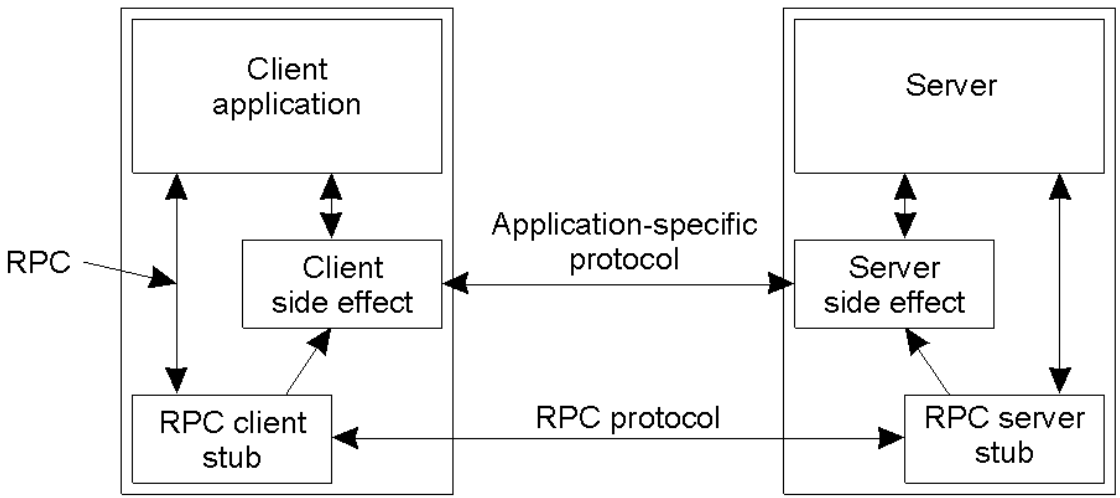

- MultiRPCs (transparenter Aufruf mehrerer Server) genutzt für Cache-Invalidierung
  (Parallele Einzelaufrufe oder Nutzung von IP-Multicast)

File IDs

Hochschule RheinMain

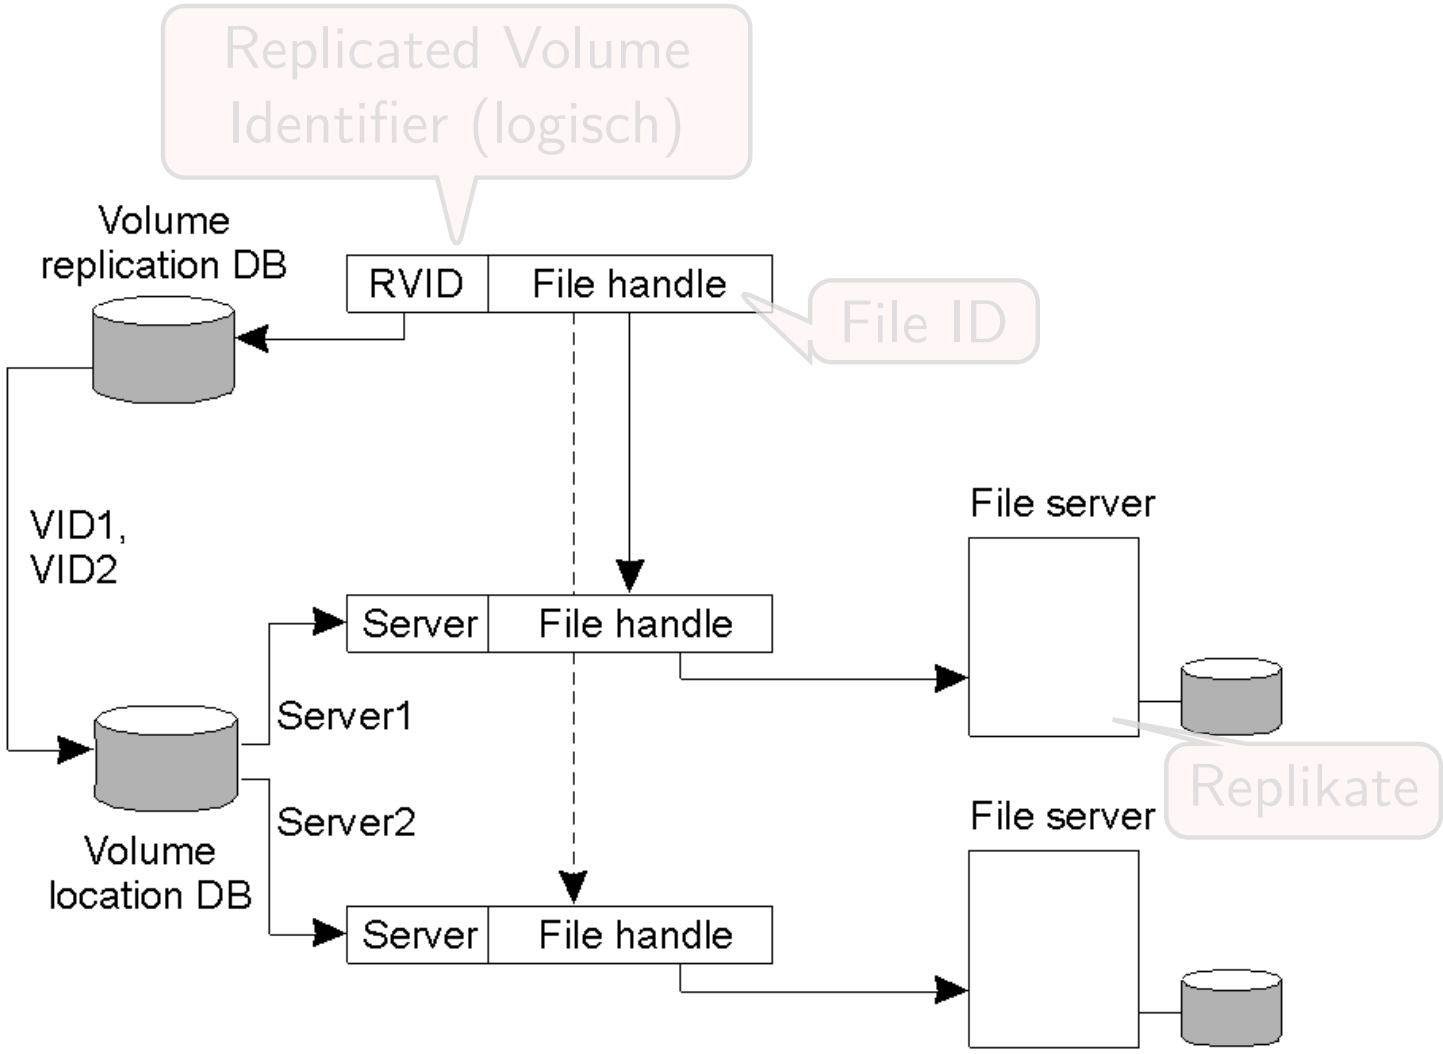

Abb. aus Tanenbaum/Steen

File IDs

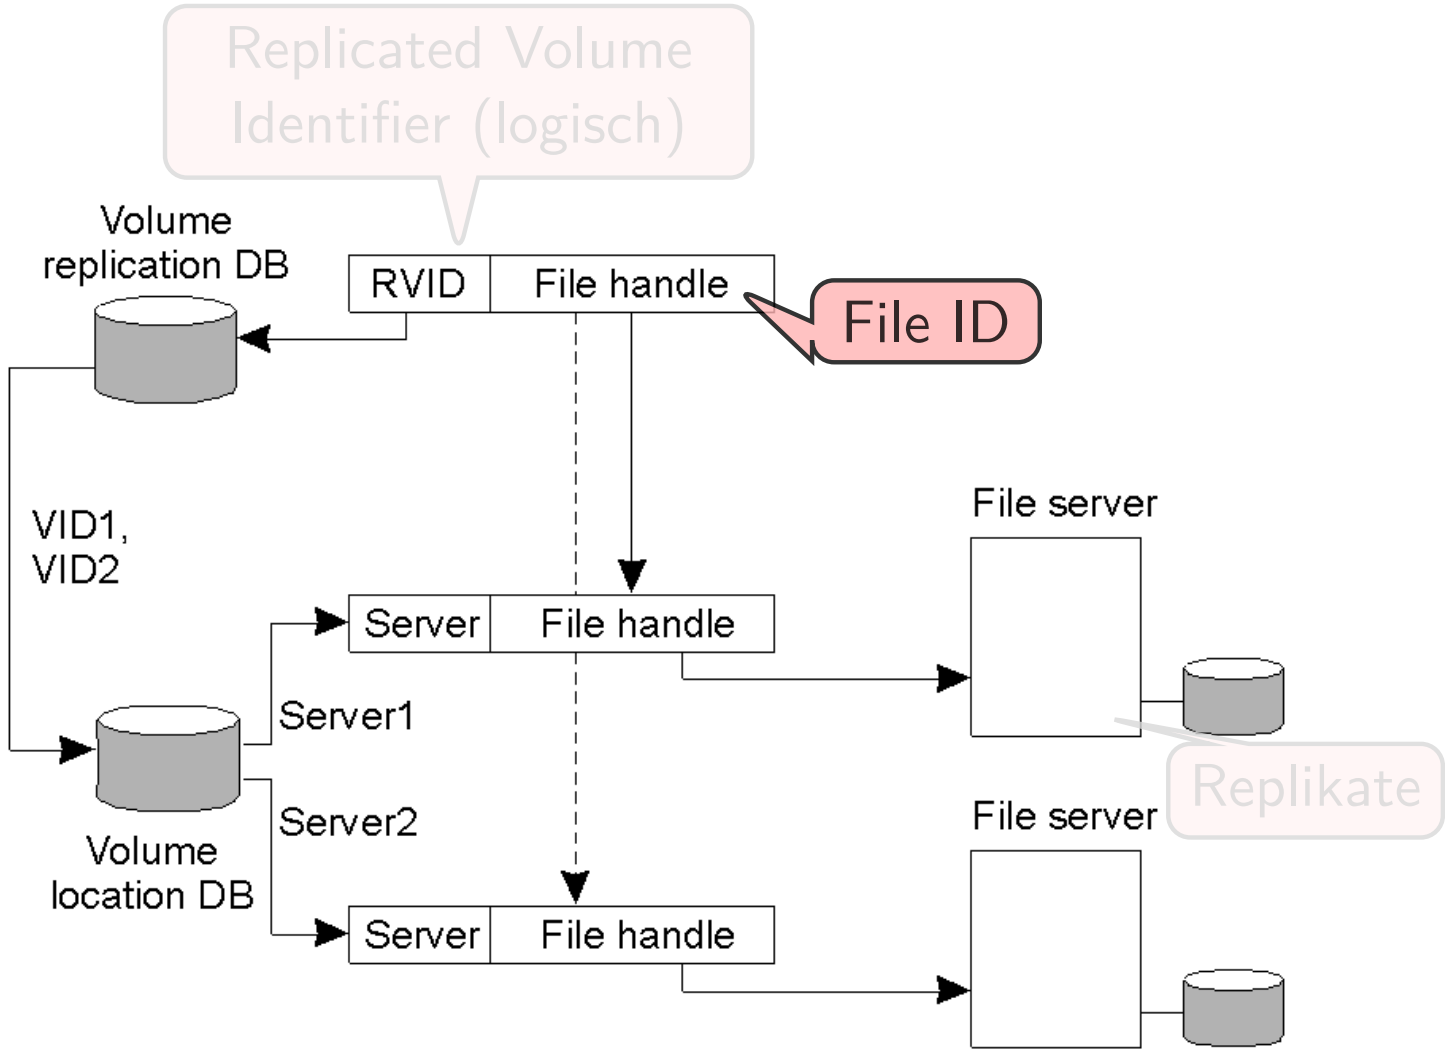

Abb. aus Tanenbaum/Steen

File IDs

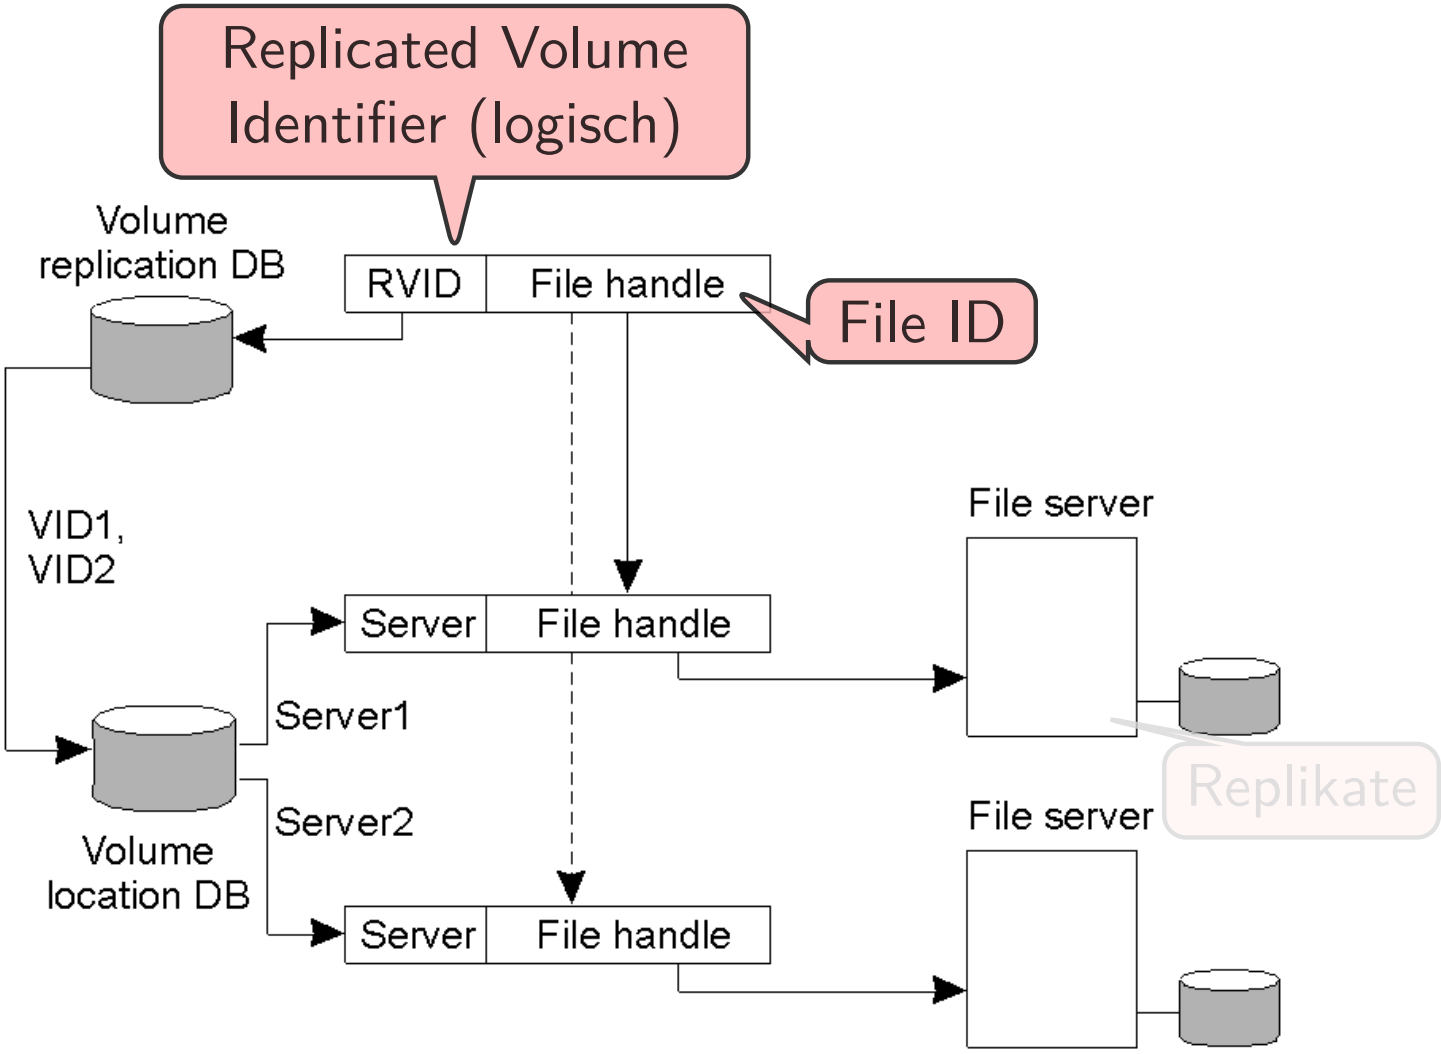

Abb. aus Tanenbaum/Steen

File IDs

Hochschule RheinMain

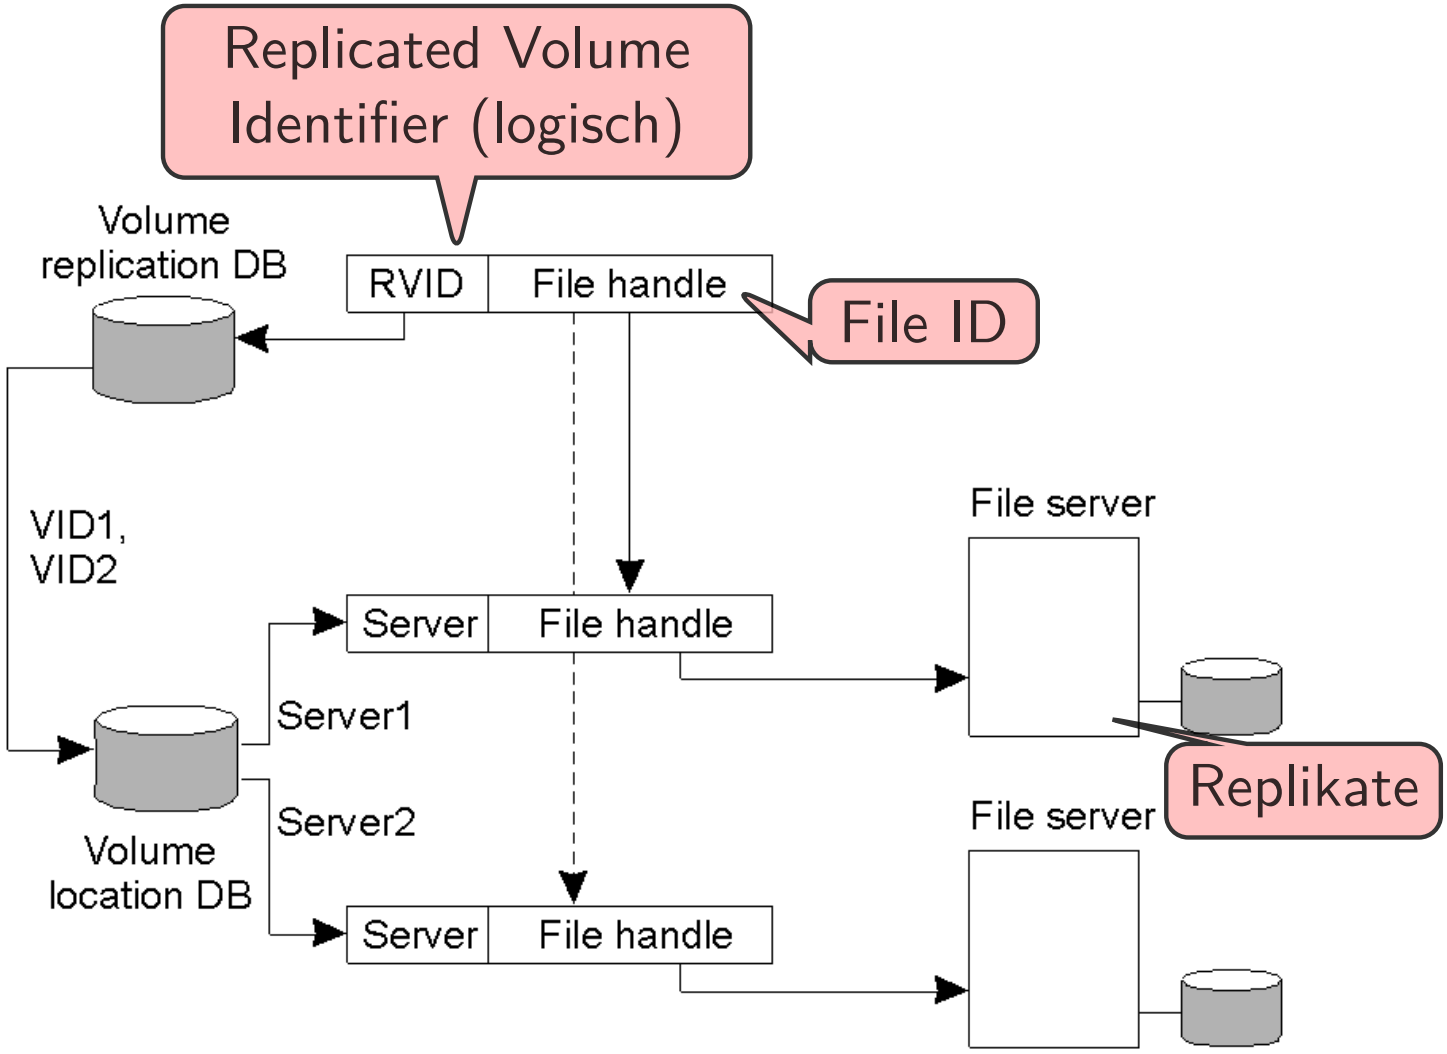

Abb. aus Tanenbaum/Steen

Eigenschaften im Normalbetrieb

- Sitzungssemantik
- ein Schreiber oder mehrere Leser
- „Transaktions“-Verhalten

unkritisch: A liest von älterer Version der Datei, arbeitet auf dieser weiter

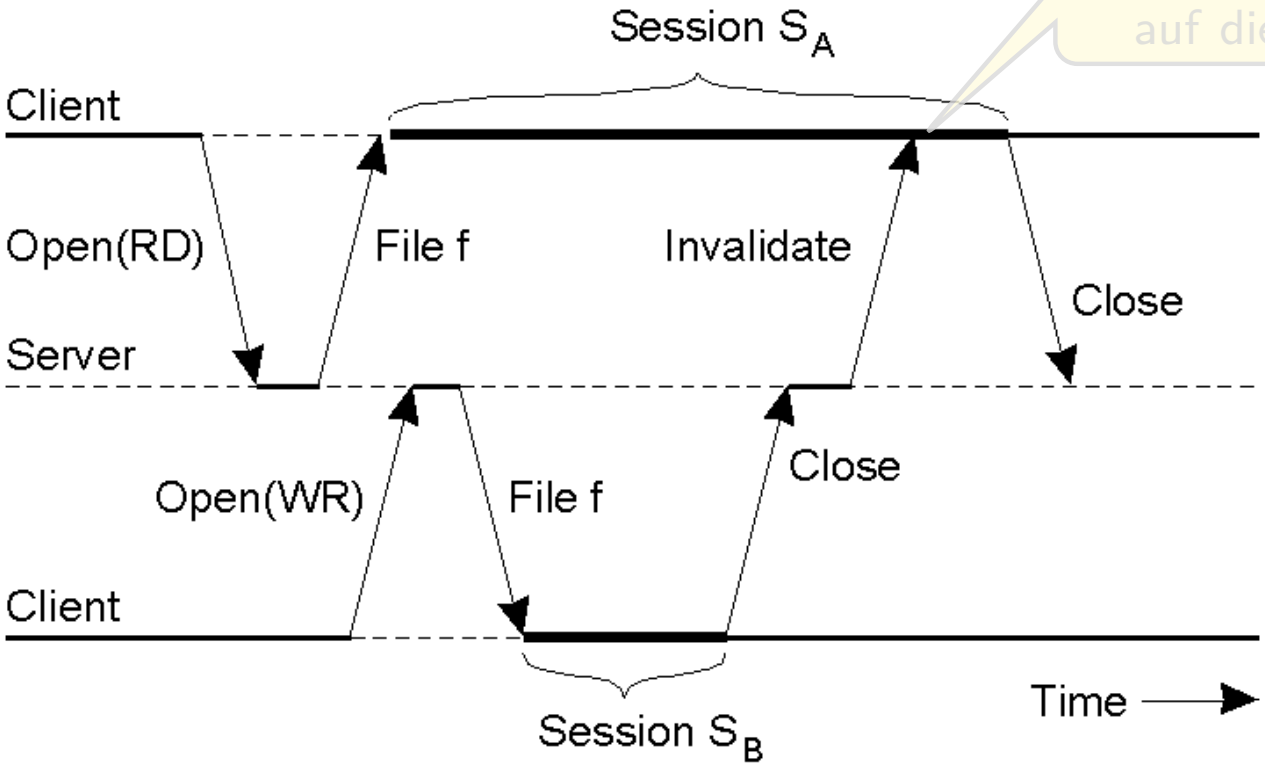

Abb. aus Tanenbaum/Steen

Eigenschaften im Normalbetrieb

- Sitzungssemantik
- ein Schreiber oder mehrere Leser
- „Transaktions“-Verhalten

unkritisch: A liest von älterer Version der Datei, arbeitet auf dieser weiter

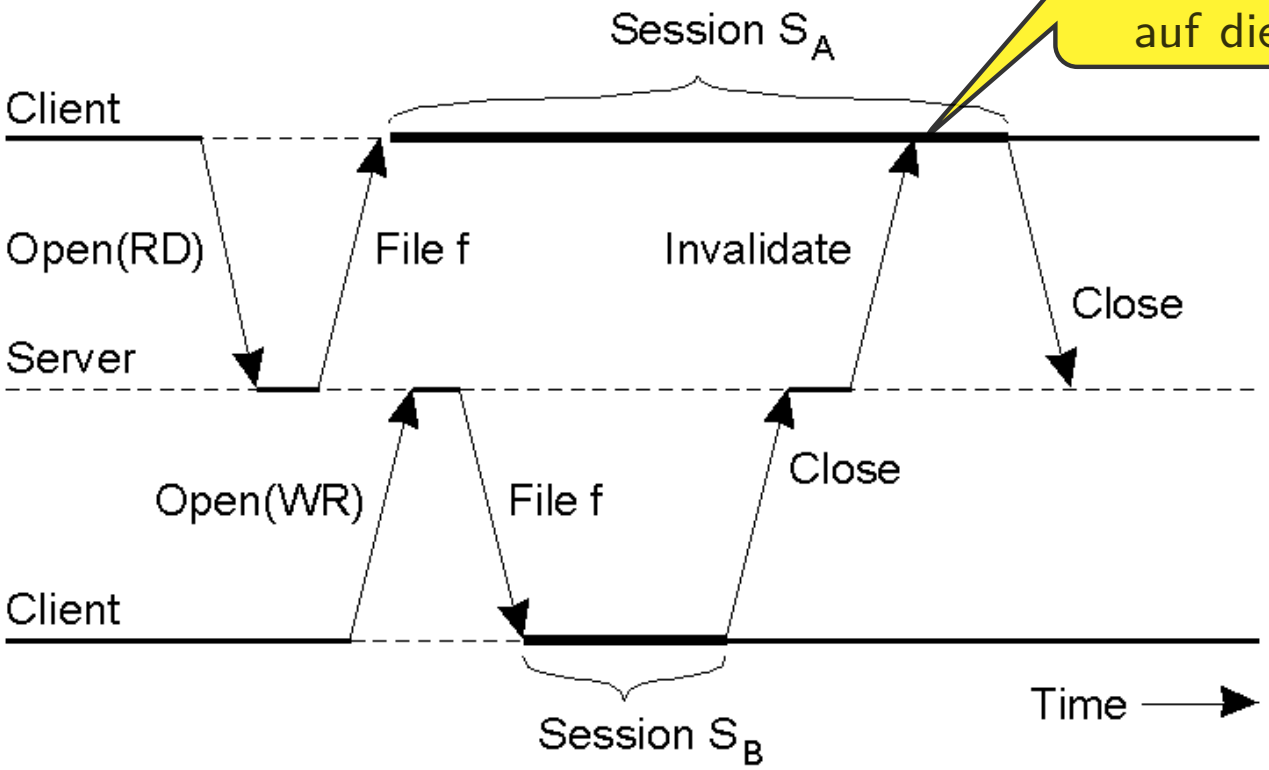

Abb. aus Tanenbaum/Steen

Caching

- Bei open() wird Datei in Client-Cache geladen
- Server gibt Callback-Versprechen
- Zur Invalidierung schickt Server Callback Break

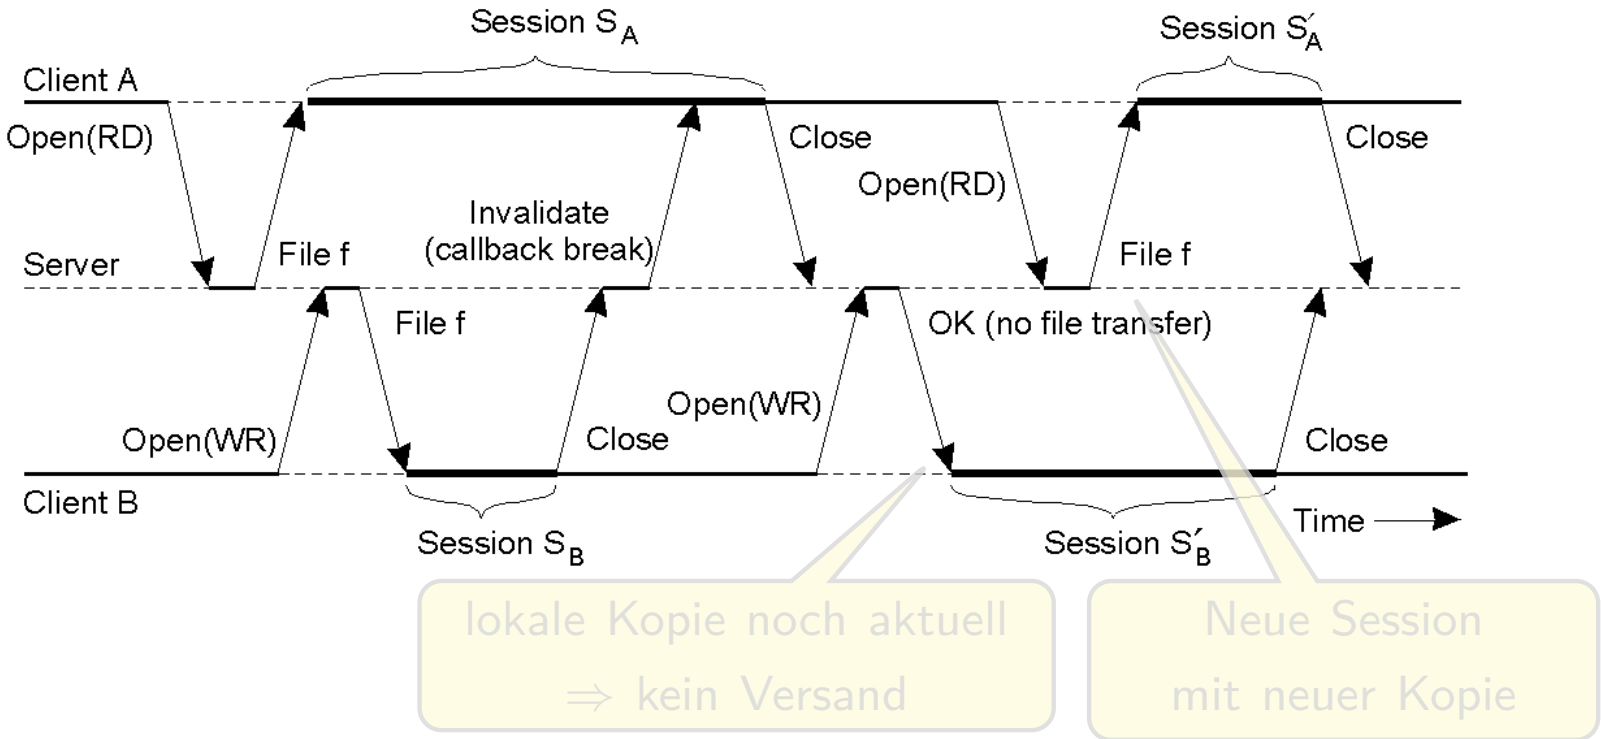

Abb. aus Tanenbaum/Steen

Caching

Hochschule RheinMain

- Bei open() wird Datei in Client-Cache geladen
- Server gibt Callback-Versprechen
- Zur Invalidierung schickt Server Callback Break

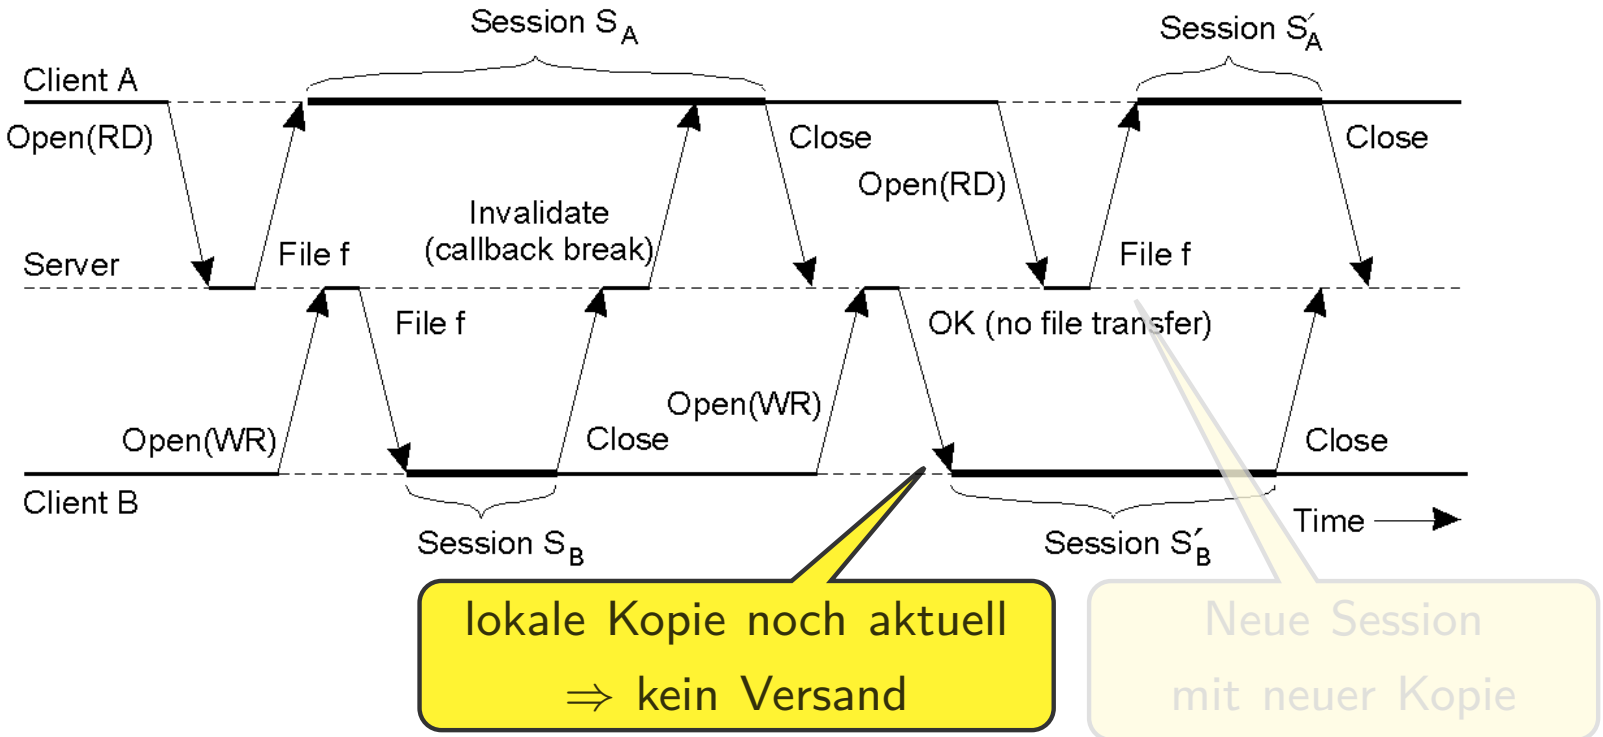

Abb. aus Tanenbaum/Steen

Caching

Hochschule RheinMain

- Bei open() wird Datei in Client-Cache geladen
- Server gibt Callback-Versprechen
- Zur Invalidierung schickt Server Callback Break

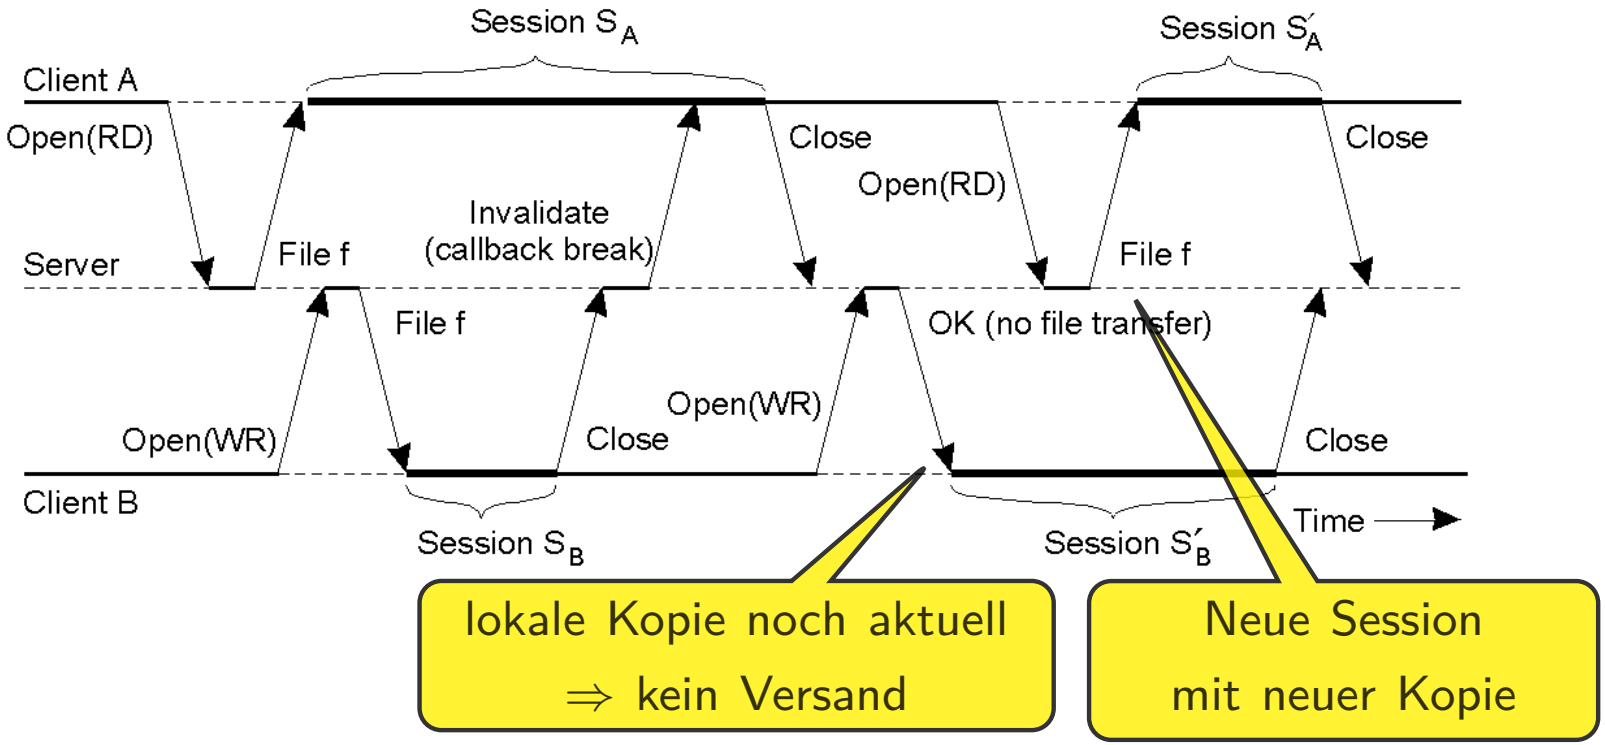

Abb. aus Tanenbaum/Steen

Server-Replikation und Netz-Partitionierung

- Volume ist Einheit der Replikation
- Volume Storage Group (VSG)
  - Menge der Server mit Kopie eines Volumes
- Accessible Volume Storage Group (AVSG)
  - Teilmenge von VSG, die Client kontaktieren kann
- Lesen von einem Replikat, Schreiben an alle mittels MultiRPC
- Optimistische Strategie für Dateireplikation
  - Bei Partitionierung dürfen mehrere Schreiber existieren und auf ihre jeweilige AVSG zurückschreiben
- Führen von Versionsvektoren entsprechend Vektorzeitstempel (vgl. Kap. 7) und Überprüfung bei Aktualisierung
- Spätere Zusammenführung verschiedener Versionen erfordert z.T. manuelle Hilfe

Verbindungsloser Betrieb

- Verbindungslos: AVSG$= \emptyset$, dann Nutzung der lokalen Kopie
- Konflikterkennung bei Übertragung auf den Server (s.o.)
- Beobachtung
  - Konflikte selten, da selten eine Datei von mehreren Prozessen gleichzeitig modifiziert wird
- Problem
  - Relevante Dateien im lokalen Cache haben, wenn Verbindungslosigkeit eintritt
- Ansatz: Hoarding (Horten von Dateien)
  - Heuristisches Verfahren
  - Explizite Angabe von Dateien und Verzeichnissen durch Benutzer
  - Priorisierung durch Abgleich mit aktueller Zugriffsinformation
  - Cache-Ausgleich (Hoard-Walk) alle 10 min
  - Gute Erfahrungen, aber es kommt natürlich vor, dass gelegentlich relevante Dateien fehlen

Zusammenfassung

File-associated data	**Read-lock**	**Write-Lock**
Issue	**NFS**	**Coda**
Design goals	Access transparency	High availability
Access model	Remote	Up/Download
Communication	RPC	RPC
Client process	Thin/Fat	Fat
Server groups	No	Yes
Mount granularity	Directory	File system
Name space	Per client	Global
File ID scope	File server	Global
Sharing sem.	Session	Transactional
Cache consist.	write-back	write-back
Replication	Minimal	ROWA
Fault tolerance	Reliable comm.	Replication and caching
Recovery	Client-based	Reintegration
Secure channels	Existing mechanisms	Needham-Schroeder
Access control	Many operations	Directory operations

Nach Tanenbaum/Steen

Speichernetze

Hochschule RheinMain

Nutzung von Netzwerktechnologie und verteilten Systemen innerhalb von Speichersystemen

Motivation

- Kostenreduktion
  - Geringere bereitgestellte Speicherkapazitäten
  - Zentrale Administration
- Höhere Flexibilität in der Zuordnung
  - Schnelle Anpassbarkeit an neue Bedürfnisse
- Skalierbarkeit
  - Kleine bis sehr große Speicherkapazitäten
- Möglichkeit für Desaster Recovery
  - Datenspiegelung an entfernte Stellen

Architekturansätze

Hochschule RheinMain

Wesentliche heutige Architekturansätze

- Direct Attached Storage (DAS) (klassischer lokaler Speicher)
- Storage Area Networks (SAN)
- Network-Attached Storage (NAS)
- Content Adressed Storage (CAS)

Im Folgenden vorgestellt

Speichersysteme als geschichtete Systeme

Hochschule RheinMain

Grundlegende Aufteilung der Funktionalität von Informationsspeicherung

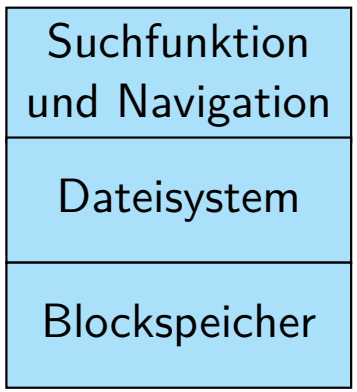

Pfadnamen, Query, Index, Metadaten, ...

Abbildung auf logische Blockmenge, z.B. NFS, AFS, Microsoft SMB/CIFS

Abbildung auf phys. Speichergerät

Überblick zur Integration von Netzen

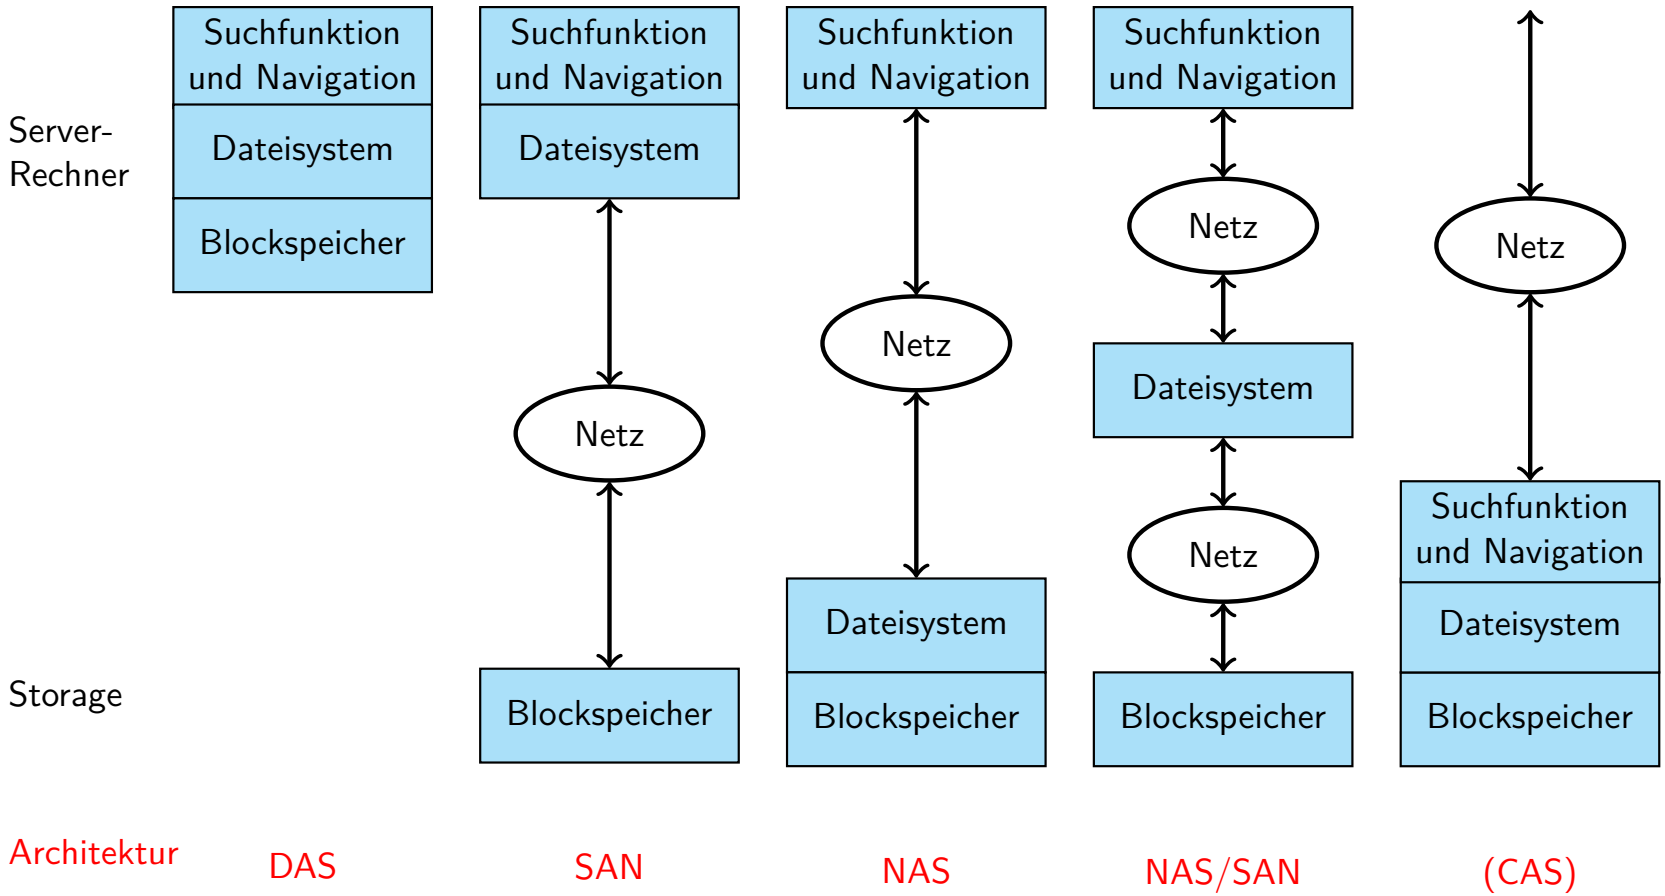

DAS: Direct Attached Storage

- Traditionelle, lokal angeschlossene Speichergeräte
- Lokales Betriebssystem enthält Dateisystem und Gerätetreiber
- Typische Geräteschnittstellen
  - IDE/ATA, SCSI, Serial ATA (SATA), ...
- Beschränkungen
  - Anzahl vorhandener Kanäle
  - Anzahl anschließbarer Devices je Kanal
  - maximale Entfernung ca. 1-25 m

  $\Rightarrow$ kein Disaster-Recovery möglich
  - Performance

  $\Rightarrow$ schlechte Skalierbarkeit

SAN: Storage Area Network

Hochschule RheinMain

Funktionsweise

- SAN offeriert Blockspeicher (z.B. Festplatten als Logical Devices)
- Server-Betriebssysteme enthalten ein oder mehrere Dateisysteme
- Blockspeicher wird über das SAN von Servern zugegriffen

Vorteile

- Sehr leichte Erweiterbarkeit
- Sehr flexible Zuordenbarkeit
- Hohe Skalierbarkeit
- Basis für Replikation, auch für Disaster Recovery
- Bootbare Netzwerkpartitionen
- Besonders geeignet für Anwendungen, die mit Volumes (ohne Dateissystem) arbeiten, z.B. DBMSe

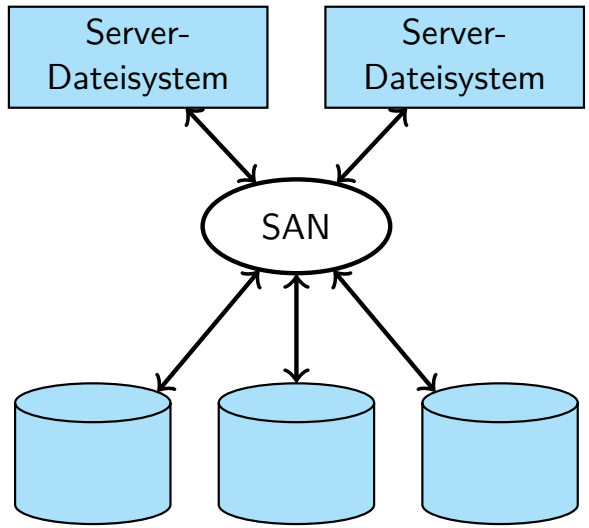

SAN: Storage Area Network(2)

Verbreitete Netzwerke

- Fibre Channel (FC)
  - Dediziertes Netzwerk mit 1/2/4/8/16 GBit/s über Glasfaser
  - geschichtetes Protokoll FC-0 bis FC-4
  - verschiedene Übertragungsprotokolle in FC-4 einbettbar, typisch: serielles SCSI-3
  - Skalierbarkeit über Switches
  - Ausdehnung bis 10-100 km
- Internet SCSI (iSCSI)
  - neuerer Standard (RFC 3720, 2004)
  - Nutzung von preiswerter Internet-Technologie zur Blockübertragung
  - TCP/IP als unterlagertes Protokoll
  - Ausdehnung beliebig
  - Security- und QoS-Standards nutzbar
  - hohes Wachstum mit Gbit/s-Ethernet erwartet

NAS: Network Attached Storage

Hochschule RheinMain

Funktionsweise

- NAS offeriert Netzwerkdateisysteme (z.B. NFS, SMB/CIFS (Server Message Block bzw. Nachfolger Common Internet File System))
- Clients können Dateisysteme nutzen

Vorteile

- Speicher-Konsolidierung
- Erweiterbarkeit
- Skalierbarkeit
- Managebarkeit
- Besonders geeignet für Anwendungen, die auf Dateizugriffen basieren, z.B. Web-Anwendungen, Home-Verzeichnisse

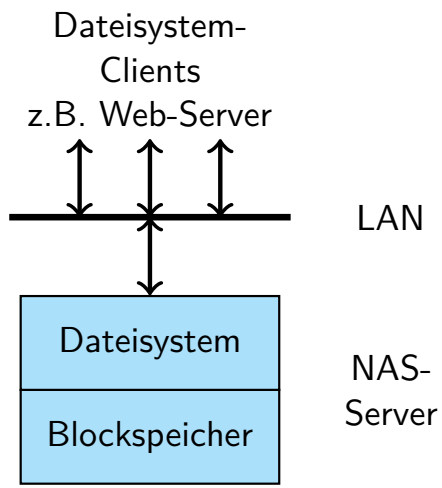

NAS: Network Attached Storage (2)

Beispiele:

- Home Server
  - Synology
  - Zyxel
- IBM Storvize V7000

NAS / SAN Verbund

Hochschule RheinMain

Funktionsweise

- NAS und SAN können kombiniert eingesetzt werden
- Vorteile lassen sich so kombinieren

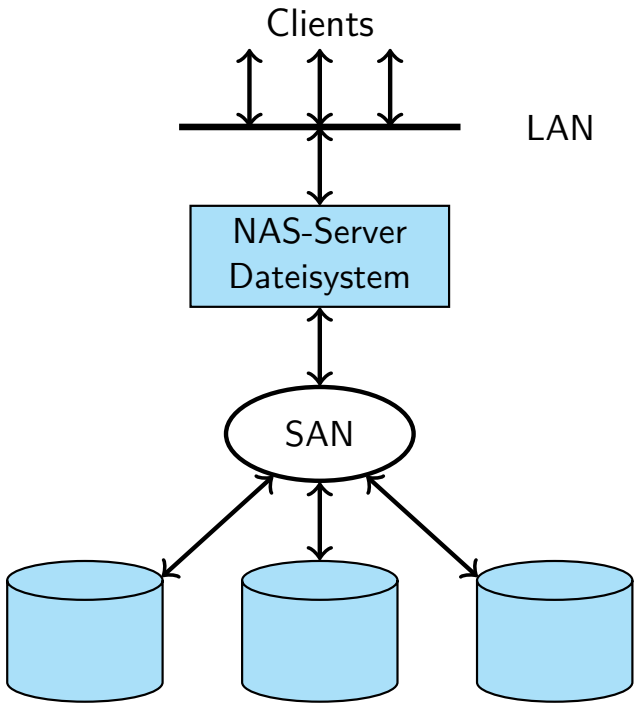

CAS: Content Adressable Storage

Grundlage des Ansatzes: Unveränderliche Information

- daher auch Fixed Content Storage (FCS) genannt
- Ziel: Archiv-Speicher

Teilproblem des Information Lifecycle Management (ILM)

- Massendaten (Hunderte von Terabytes bis Petabytes)
- Langlebigkeit
- Integrität
- Unveränderbarkeit von Dokumenten z.T. gesetzlich gefordert

Anwendung im Bereich Content Management

- Digitale Medien (Ton-, Bild-Dokumente)
- email-Archivierung
- Gesundheitswesen (Röntgenbilder etc.)
- ...

CAS: Content Adressable Storage (2)

Funktionsweise

- Content Identifier als Referenz
- Bestimmung eines Content-Identifiers
  - ausschließlich aus Inhalt (analog Hash-Wert) $\Rightarrow$ ortsunabhängig
  - oder aus Speicherort (invertiert)
- System ermittelt aus Content Identifier Location für Zugriff

Beispiele

- Erstes System: EMC Centera 2002
- iTernity iCAS (Software-Lösung)
- Versch. Open Source Lösungen, z.B. Keep Content Adressable Storage

Zusammenfassung

- Verteilte Dateisysteme ermöglichen den nebenläufigen Zugriff unterschiedlicher Nutzer auf Dateien unabhängig von ihrem Speicherort.
- Der Zugriff auf Dateien kann je nach Konsistenz-Semantik zu unterschiedlichen Ergebnissen führen.
- Durch Aufteilung der Funktionalität zur Informationsspeicherung auf unterschiedliche Systeme im Netzwerk lassen sich u.a. Skalierbarkeit, Fehlertoleranz und Erweiterbarkeit verbessern.